

МИНОБРНАУКИ РОССИИ

Федеральное государственное автономное образовательное
учреждение высшего образования
«Южный федеральный университет»

Институт математики, механики
и компьютерных наук им. И. И. Воровича

Кафедра алгебры и дискретной математики

Пономарев Матвей Борисович

**РАЗРАБОТКА МОДЕЛИ МАШИННОГО ОБУЧЕНИЯ ДЛЯ
РАСПОЗНАВАНИЯ ПРЕДВЕСТНИКОВ ЗЕМЛЕТРЯСЕНИЙ
НА ОСНОВЕ АНАЛИЗА БИОЭЛЕКТРИЧЕСКОЙ
АКТИВНОСТИ ГОЛОВНОГО МОЗГА ЖИВОТНОГО**

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
по направлению подготовки
01.03.02 – Прикладная математика и информатика

Научный руководитель –
доцент., к. т. н. Адигеев Михаил Георгиевич

Допущено к защите:
заведующий кафедрой _____ Штейнберг Б. Я.

Ростов-на-Дону – 2026

Оглавление

Постановка задачи	3
Введение	4
1. Материалы и методы.....	9
2. Поиск ширины аномального окна	15
3. Программная реализация	22
3.1. Логика работы с временными рядами	23
3.2. Предобработка	23
3.3. Байесовский метод.....	23
Литература.....	27
Приложение.....	28

Постановка задачи

В постановке задачи коротко (по пунктам) указывается, что необходимо сделать в рамках работы. Раздел «Постановка задачи» должен соответствовать заданию на курсовую или выпускную квалификационную работу, подписанному научным руководителем.

Введение

Естественнонаучная постановка задачи

На данный момент не существует точной модели, описывающей физические процессы перед землетрясением (Родкин, 2011). Тем не менее, исследования продолжаются, так как накоплено много надежных данных о различных признаках приближающегося землетрясения: изменениях электромагнитных полей, химического состава вод и газов, деформациях поверхности и других (Cicerone et al., 2009; Geller, 2007; Ma et al., 2021; Chiodini et al., 2020).

По-видимому, некоторые из этих признаков способны улавливать животные. Известно множество случаев, когда незадолго до подземных толчков наблюдалось необычное поведение: собаки начинали громко лаять, кошки и собаки пытались убежать, крысы покидали норы, пчелы — ульи, а птицы издавали частые крики (Kirschvink, 2000). Также зафиксированы случаи, когда жабы покидали места своего обитания до завершения серии повторных толчков (Grant et al., 2011). В некоторых исследованиях даже численно показана связь между активностью мышей за день до землетрясения и изменениями геомагнитного поля (Yokoi et al., 2003).

С точки зрения эволюции такая чувствительность могла закрепиться, потому что одно крупное землетрясение (даже если оно случается раз в 50 поколений) способно уничтожить 10

Известно, что реакция животных на предвестники землетрясений связана с состоянием стресса или повышенной тревоги. Стресс напрямую влияет на цикл сна и бодрствования, а также на общую активность (Rampin et al., 1991; Meerlo et al., 1997; Palma et al., 2000; Adrien et al., 1991). Согласно теории Ганса Селье (Selye, 1950), стресс — это общая реакция организма на вредные воздействия. Ее механизм связан с выбросом определенных гормонов (кортикотропин-рилизинг-гормона, а затем глюкокортикоидов). Выделение этих гормонов также подчиняется суточным ритмам, что задает циклический характер активности у грызунов (Herman et al., 2016;

Kalsbeek et al., 2012). Колебания уровня этих гормонов меняют структуру сна у крыс (Bradbury et al., 1998). При этом разные виды стресса приводят к разным изменениям в структуре сна — например, одни увеличивают долю быстрого сна, а другие — долю медленного (Rampin et al., 1991; Meerlo et al., 1997; Palma et al., 2000; Adrien et al., 1991; Sanford et al., 2010).

Сон млекопитающих достаточно хорошо изучен. В нем выделяют две основные фазы: быстрый сон (с быстрыми движениями глаз, REM) и медленный сон (Rytkonen, 2011; Saevskiy, 2025; Kostin, 2019; Vyazovskiy, 2005; Lyamin, 2008). Для быстрого сна характерны низкоамплитудные высокочастотные колебания на электроэнцефалограмме и расслабление мышц. Эти две фазы циклически сменяют друг друга, причем медленный сон всегда предшествует быстрому. У грызунов сон, как правило, состоит из множества повторяющихся эпизодов в течение суток, причем спят они в основном в светлое время суток (Franken et al., 1999; Weber, Dan, 2016).

Исходя из вышесказанного, в данной работе мы исследовали изменения сна крыс как возможный результат стресса, вызванного воздействием факторов, предшествующих землетрясениям. Для исследования был выбран быстрый сон как наиболее чувствительный показатель стресса животного. Отдельное внимание уделено тому, за какой промежуток времени до землетрясения наблюдаются эти изменения.

Машинное обучение и анализ данных

Применение методов машинного обучения к описанной задаче выглядит естественным шагом: мы имеем многомерный временной ряд физиологических показателей, предположительно связанный с редкими внешними событиями, и хотим обнаружить эту связь, не имея строгой физической модели процесса. Однако специфика предметной области накладывает ряд серьезных ограничений, которые необходимо учитывать при выборе и оценке моделей.

Проблема сверхмалой выборки. Землетрясения достаточной силы, ощутимые на территории расположения лаборатории, являются ред-

кими событиями. Даже при длительном непрерывном мониторинге число таких событий, попадающих в период регистрации, обычно исчисляется единицами или первыми десятками. Это фундаментальное ограничение: в отличие от типичных задач машинного обучения, мы не можем рассчитывать на тысячи или даже сотни примеров целевого события. Большинство мощных моделей, таких как глубокие нейронные сети и ансамбли, являются "черными ящиками" (Alan Turing Institute) и требуют значительно большего объема данных для обучения без переобучения. В данной ситуации предпочтительными оказываются экономные по числу параметров методы: линейные модели с регуляризацией, метод опорных векторов для обнаружения выбросов. Байесовские модели с сильными априорными предположениями, кроме того, позволяют естественным образом количественно оценить неопределенность, связанную с малым объемом данных (Šinkovec, 2022). Вместо точечных прогнозов такая модель выдает распределение возможных значений параметров, ширина которого отражает степень нашей неуверенности.

Неоднородность данных. Обучающая и тестовая выборки в данной задаче заведомо не являются независимыми и одинаково распределенными (i.i.d.). Данные представляют собой непрерывный временной ряд, где соседние наблюдения сильно скоррелированы. Кроме того, сами условия сбора данных могут меняться: сезонные факторы влияют на поведение животных, старение особи меняет ее физиологию, возможны дрейфы регистрирующей аппаратуры. Наконец, разные землетрясения различаются по магнитуде, расстоянию до эпицентра, глубине очага и геологическому контексту, а значит, и по характеру предвестников, достигающих лаборатории. Все это означает, что модель, хорошо работающая на одном временном отрезке, может оказаться несостоятельной на другом, если не учитывать перечисленные источники вариативности. Иерархические байесовские модели частично решают эту проблему, позволяя включать в структуру модели параметры, описывающие индивидуальные особенности животных и характеристики конкретных событий.

Специфика работы с временными рядами. Поскольку данные

являются временным рядом, прямое применение стандартных методов классификации или регрессии, предполагающих независимость наблюдений, приводит к некорректным выводам. Временная структура порождает автокорреляцию: если крыса сегодня показала аномально высокую долю быстрого сна, то и завтрашнее значение, вероятно, будет отклоняться от среднего просто в силу инерционности физиологических процессов. Неучет этой зависимости ведет к ложной оценке значимости найденных закономерностей. При кросс-валидации временных рядов нельзя использовать случайное разбиение на фолды — это нарушает временной порядок и создает риск "утечки данных" из будущего, что ведет к чрезмерно оптимистичным оценкам (Bergmeir Benítez, 2012; scikit-learn Developers) . Необходимо применять схемы с сохранением временного порядка, такие как скользящий контроль с расширяющимся окном (forward-chaining), чтобы обучение всегда происходило на прошлом, а тестирование на будущем (RemNote Study Deck) . Альтернативно, в байесовском подходе можно явно моделировать автокорреляционную структуру остатков, например, с помощью авторегрессионных компонент или гауссовских процессов, что позволяет корректно отделить эффект предвестников от естественной временной зависимости.

Проблема множественного тестирования. В ситуации, когда данных мало, а потенциальных предикторов (различные геофизические параметры, их лаги, частотные компоненты) много, возникает риск ложноположительных находок. Перебор большого числа гипотез без учета поправки на множественность почти гарантирует обнаружение статистически значимых, но содержательно пустых корреляций. Байесовский подход смягчает эту проблему, поскольку апостериорное распределение естественным образом штрафует сложные модели через маргинальное правдоподобие, а использование регуляризирующих априорных распределений, таких как horseshoe prior или spike-and-slab prior, позволяет автоматически отсеивать неинформативные предикторы (Denti, 2021) .

Интерпретируемость и научная ценность. В отличие от многих прикладных задач машинного обучения, где главный критерий — точность предсказания, в данной работе не менее важна интерпретируемость резуль-

тата. Нас интересует не только сам факт обнаружения аномалии перед землетрясением, но и количественная оценка временного окна, в котором эта аномалия проявляется, направленность изменений и степень индивидуальной вариабельности.

Байесовский вывод здесь предпочтительнее многих "черных ящиков" так как дает прямые вероятностные утверждения об интересующих величинах. Таким образом, с учетом перечисленных ограничений, в данной работе мы фокусируемся на байесовских методах анализа временных рядов как на инструменте, позволяющем совместить обнаружение аномальных паттернов сна с корректным учетом неопределенности, порожденной малым объемом данных и их сложной временной структурой. Основное внимание уделяется не столько построению предсказательной модели землетрясений, сколько проверке гипотезы о наличии устойчивого физиологического отклика и характеристике его временных свойств.

1. Материалы и методы

В настоящем исследовании использованы материалы и методы, а также промежуточные результаты достижений исследовательской лаборатории разработки перспективных технологий краткосрочного сейсмопрогнозирования, учрежденной в рамках программы Стратегического академического лидерства Южного федерального университета (СП-11-24-02, КБК СП02/S4_0708 Приоритет_11, № НИОТКР 124060400026-7) на базе НИТЦ нейротехнологий ЮФУ при поддержке Фонда перспективных исследований (Договор от 23.12.2021 г. № 6/242/2022-2023AB) и совместно с КФ ФИЦ ЕГС РАН.

Экспериментальные животные и условия содержания

Эксперименты по получению сигнала интеркортикальной ЭЭГ проводились на базе Камчатского филиала Единой геофизической службы РАН (г. Петропавловск-Камчатский, станция «Институт»). Объектом исследования служили взрослые самцы крыс линии пасюк массой от 200 до 250 г. Животные содержались поодиночке в прозрачных пластиковых боксах размером $30 \times 30 \times 40$ см с перфорированными стенками. В помещении поддерживалась постоянная температура ($23 \pm 1^\circ\text{C}$) и фиксированный 12-часовой цикл освещения (12 ч свет / 12 ч темнота). Доступ к пище и воде был свободным. Все процедуры были одобрены комиссией по биоэтике Южного федерального университета.

Регистрация биоэлектрической активности

Для оценки состояний сна и бодрствования непрерывно регистрировалась электрическая активность коры больших полушарий (ЭКоГ) и гиппокампа (ЭСКоГ). Для этого сотрудники станции вживляли электроды животным под наркозом в область сенсомоторной коры и в поле СА1

Рис. 1. 5-секундная эпоха регистрируемого сигнала ЭЭГ крысы.

гиппокампа. Электроды соединялись с разъемом, который фиксировался на поверхности черепа. Регистрацию начинали не ранее чем через неделю после операции, чтобы исключить влияние восстановительного периода.

Запись сигналов велась с помощью 32-канального усилителя RBX2/32sp-r/32fp300 (Plexon Corp., США) и аналого-цифрового преобразователя L-ACRD (модель E 14-440). Частота оцифровки составляла 1 кГц по каждому каналу.

Раз в 24 часа суточная запись ЭЭГ выгружалась в объектное хранилище. Пример визуализации 5-секундной эпохи (1250 отсчетов) представлен на рисунке 1

Алгоритм классификации состояний сна и бодрствования

Для извлечения информации о функциональном состоянии животных из зарегистрированных сигналов использовался автоматический алгоритм стадирования, разработанный сотрудниками НИТЦ нейротехнологий ЮФУ и реализованный на языке Python. Алгоритм является упрощенной версией метода, описанного в работе [7](Saevski), и относит каждую эпоху записи к одному из трех состояний: бодрствование, медленный сон (МС) или парадоксальный сон (ПС). Процедура обработки состоит из следующих шагов:

- 1) Суточная запись сигналов разбивается на неперекрывающиеся эпохи длительностью 5 с.
- 2) Эпохи, содержащие высокоамплитудные артефакты (например, вызванные движением животного), исключаются из дальнейшего анализа.
- 3) Для каждой оставшейся эпохи с помощью быстрого преобразования Фурье вычисляются спектры мощности сигналов ЭКоГ и ЭСКоГ с раз-

решением по частоте 0.5 Гц.

- 4) **Детекция МС:** В спектре мощности ЭКоГ выделяется дельта-диапазон (2.5–5.5 Гц) [4](Fang2010). Суммарная мощность в этом диапазоне образует временной ряд, в котором методом гауссовых смесей выделяются две компоненты. Компонента с более высокой средней мощностью интерпретируется как медленный сон.
- 5) **Детекция ПС:** В спектре мощности ЭСКоГ выделяется тета-диапазон (5.5–8 Гц) [8](Vyazovskiy2005). Для каждой эпохи вычисляется отношение мощности тета-ритма к мощности дельта-ритма. В полученном ряду выделяются высокоамплитудные пики, которые маркируются как эпизоды парадоксального сна.
- 6) Результаты шагов 4 и 5 объединяются: эпохи, классифицированные как МС или ПС, получают соответствующие метки; все оставшиеся эпохи считаются бодрствованием.

Результатом работы алгоритма является гипнограмма — последовательность меток состояний для каждой 5-секундной эпохи на протяжении всей суточной записи. Именно гипнограмма служит исходным материалом для дальнейшего анализа связи структуры сна с сейсмической активностью.

Выборка сейсмических событий

Были использованы данные 14 сейсмических событий, произошедших в 2022-2025 годах; даты событий и номера крыс, используемых для анализа приведены в Таблице 1. Критериями отбора сейсмических событий служили инструментальная интенсивность (> 2 баллов) и доступность данных биоэлектрической активности мозга крысы на станции «Институт» (г. Петропавловск-Камчатский, Россия, 53.06° N, 158.61° E) за 10 дней до и 10 дней после сейсмического события. Здесь под инструментальной интенсивностью понимается оценка по пиковым значениям прошедших предвари-

тельную фильтрацию в полосе $[0.1; 10]$ Гц сигналов акселерометров во время землетрясения (по ГОСТ Р 57546–2017), на станции «Институт». Стоит обратить внимание, что для сейсмических событий 02.07.2025 и 20.07.2025 на станции присутствовало сразу 4 грызуна (R1, R2, R3, R4), доступность сигнала которых мы считаем достаточным для дальнейшего анализа.

Таблица 1. Выборка сейсмических событий

ИД крысы	Дата
R2	2022-11-07
R2	2022-11-18
R2	2023-04-03
R2	2023-04-11
R2	2023-04-18
R2	2023-04-21
R2	2023-05-03
R2	2023-05-09
R2	2024-09-30
R2	2024-10-29
R3	2025-01-23
R3	2025-03-14
R1	2025-07-02
R2	2025-07-02
R3	2025-07-02
R4	2025-07-02
R1	2025-07-20
R2	2025-07-20
R3	2025-07-20
R4	2025-07-20

Суточные профили парадоксального сна и их признаки

На основании результатов стадирования функционального состояния животных строились суточные профили парадоксального сна (ПС). Под суточным профилем понимается временной ряд, отражающий динамику доли времени, проведенного животным в состоянии ПС, вычисленной в

Рис. 2. Профиль парадоксального сна крысы.

пределах последовательных временных окон на протяжении одной суточной гипнограммы.

В общем виде профиль определяется двумя параметрами: шириной окна W и шагом смещения S . Выбор конкретных значений этих параметров представляет собой отдельную задачу, и их оптимальные значения для данного исследования еще предстоит определить. С одной стороны, слишком узкое окно приводит к излишней зашумленности профиля и появлению большого числа нулевых значений в тех интервалах, где эпизоды ПС просто не успевают реализоваться. С другой стороны, чрезмерно широкое окно сглаживает суточную динамику, скрывая потенциально важные детали поведения.

На рисунке 2 изображен пример нормального профиля парадоксального сна, полученного с использованием следующего набора параметров: ширина окна $W = 2$ часа, шаг $S = 2$ часа (непересекающиеся окна). При таком разбиении суточная запись описывается набором из 12 значений, что позволяет, с одной стороны, достаточно детально проследить циркадианный ритм животного (высокая доля ПС в светлую фазу, низкая — в темную), а с другой — получить приемлемую гладкость профиля без чрезмерного шума. В ходе исследования, при переходе к количественному анализу, параметры W и S будут уточнены в настоящей работе, в том числе с использованием формальных критериев оптимальности, таких как максимизация апостериорной вероятности модели или минимизация ошибки предсказания на отложенных данных.

Для компактного описания суточной динамики ПС и последующего статистического анализа вводятся несколько числовых характеристик, вычисляемых по профилю $P = \{p_1, p_2, \dots, p_N\}$, где p_i — доля ПС в i -м временном окне, а N — число окон в суточной записи.

Среднее значение профиля характеризует общий уровень ПС в течение рассматриваемого интервала — сутки, день или ночь — и опреде-

ляется как

$$\bar{P} = \frac{1}{N} \sum_{i=1}^N p_i. \quad (1)$$

Размах профиля отражает контраст между максимальной и минимальной долей ПС и вычисляется по формуле

$$R = \max(P) - \min(P). \quad (2)$$

Данный параметр позволяет одним числом охарактеризовать выраженность циркадианного ритма: как правило, максимум профиля приходится на светлую фазу суток, когда у грызунов наблюдается наибольшая доля сна, а минимум — на темную, соответствующую периоду активности. Пример перехода от полных суточных профилей к значениям размаха показан на рис. 3 (А и Б).

Также в качестве характеристик состояния стресса животного мы будем рассматривать **смещение** и **куртозис** профиля парадоксального сна, однако позже мы покажем, что эти величины не несут статистической ценности для решения нашей задачи

Смещение профиля количественно оценивает асимметрию распределения значений p_i относительно среднего и задается стандартизованным третьим центральным моментом:

$$\gamma_1 = \frac{\frac{1}{N} \sum_{i=1}^N (p_i - \bar{P})^3}{\left(\frac{1}{N} \sum_{i=1}^N (p_i - \bar{P})^2 \right)^{3/2}}. \quad (3)$$

Положительное смещение указывает на то, что профиль содержит относительно немного высоких значений (пиков ПС) на фоне преимущественно низких, тогда как отрицательное — на присутствие редких провалов на фоне общего высокого уровня.

Эксцесс (куртозис) характеризует «островершинность» распределения значений профиля, то есть степень концентрации значений вблизи среднего по сравнению с нормальным распределением. Выборочный экс-

цесс вычисляется как

$$\gamma_2 = \frac{\frac{1}{N} \sum_{i=1}^N (p_i - \bar{P})^4}{\left(\frac{1}{N} \sum_{i=1}^N (p_i - \bar{P})^2 \right)^2} - 3. \quad (4)$$

Вычитание тройки нормирует эксцесс таким образом, что для нормального распределения $\gamma_2 = 0$. Положительные значения говорят о более тяжелых хвостах и/или более острой вершине, отрицательные — о более равномерном распределении по диапазону.

Перечисленные характеристики вычисляются не только для полного суточного профиля (24-часовой интервал), но и отдельно для его светлой и темной половин. Такой подход позволяет разделить вклад периодов покоя и активности в итоговые показатели и, потенциально, обнаружить дифференцированные эффекты воздействия геофизических факторов: например, изменение размаха может быть обусловлено преимущественно снижением доли ПС именно в светлое время суток, тогда как ночной сон остается неизменным. Аналогичная логика применима и к остальным метрикам.

Таким образом, каждые сутки наблюдений описываются набором из нескольких чисел (среднее, размах, смещение, эксцесс) для полного профиля, а также для его дневного и ночного фрагментов. Эти значения, оптимальный набор которых мы определим в ходе исследования, формируют многомерный временной ряд, который в дальнейшем анализируется на предмет связи с сейсмическими событиями и их предвестниками.

2. Поиск ширины аномального окна

Поиск точки разладки

Целью этой главы является проверка гипотезы о существовании статистически значимого изменения характеристик парадоксального сна (ПС) у крыс в период, непосредственно предшествующий сейсмическому событию, определение их оптимального набора и количественная оценка вре-

менной ширины окна, в котором данная аномалия проявляется.

Для достижения этой цели в рамках исследования решаются следующие задачи:

1. Построение многомерных временных рядов признаков ПС (среднее, размах, смещение, эксцесс за день/ночь/сутки) для интервалов длительностью 10 суток, непосредственно предшествующих каждому из зарегистрированных землетрясений.
2. Разработка статистического метода, позволяющего обнаруживать момент резкого изменения свойств (точку разладки, changepoint) в построенных временных рядах в условиях крайне малого числа наблюдений.
3. Применение выбранного метода к полученным данным и идентификация временного положения точки разладки τ относительно момента основного толчка.
4. Оценка неопределённости положения τ и амплитуды изменения параметров ПС, а также проверка робастности выводов относительно индивидуальных особенностей животных и параметров предварительной обработки сигнала.

Формирование временных рядов и постановка задачи о разладке

Для каждого из E сейсмических событий, удовлетворяющих критериям отбора (Таблица 1), и для каждой крысы, по которой доступна непрерывная гипнограмма за соответствующий период, строится индивидуальный временной ряд. Под временным рядом понимается последовательность значений признаков ПС, вычисленных для последовательных суток на интервале в 10 дней, непосредственно предшествующих моменту землетрясения.

Пусть момент основного толчка соответствует моменту времени t_{event} . Рассматривается предшествующий интервал, состоящий из дискретных временных отсчётов $t \in \{1, 2, \dots, N\}$, где $N = 10$ соответствует числу анализируемых суток. Для каждого дня t и для каждого животного j вычисляется вектор признаков $\mathbf{x}_t^{(j)}$, характеризующий профиль ПС за соответствующие сутки. В общем случае данный вектор может включать следующие компоненты, вычисленные как для полных суток, так и отдельно для светлой и тёмной фаз:

- среднюю долю ПС $\bar{P}_t$;
- размах профиля R_t ;
- смещение $\gamma_{1,t}$;
- эксцесс $\gamma_{2,t}$.

Таким образом, для каждого события формируется многомерный временной ряд, в котором каждому из десяти предшествующих дней поставлен в соответствие набор физиологических характеристик сна животного.

Ввиду выраженных индивидуальных различий в абсолютных значениях параметров сна между особями (например, различный средний уровень доли ПС или амплитуда циркадианного ритма), прямое объединение сырых значений признаков в единую выборку некорректно. Поскольку предметом анализа являются качественные, а не количественные изменения динамики ПС, применяется предварительная нормировка. Для каждой крысы и каждого события индивидуальный 10-дневный профиль признака нормируется методом минимаксного масштабирования (min-max scaling) в диапазон $[0, 1]$. Данная процедура устраняет влияние индивидуального масштаба вариабельности, сохраняя при этом относительную временную динамику внутри каждого окна.

Основная статистическая задача, решаемая в данном разделе, заключается в поиске точки разладки (changepoint) — момента времени τ , разделяющего весь 10-дневный интервал на два качественно различных участка: фоновый период и период аномальных значений, вызванных, предположи-

тельно, воздействием предвестников землетрясения. Формально предполагается, что наблюдения $\mathbf{x}_t$ порождаются вероятностным распределением, параметры которого могут изменяться в некоторый неизвестный момент τ :

$$\mathbf{x}_t \sim \begin{cases} p(\mathbf{x}_t \mid \boldsymbol{\theta}_1), & \text{если } t < \tau, \\ p(\mathbf{x}_t \mid \boldsymbol{\theta}_2), & \text{если } t \geq \tau, \end{cases} \quad (5)$$

где $\boldsymbol{\theta}_1$ и $\boldsymbol{\theta}_2$ — векторы параметров распределения до и после точки разладки соответственно, а сам момент τ также подлежит оцениванию по данным.

Выбор метода оценивания

Задача обнаружения точки разладки в коротких временных рядах обладает рядом особенностей, которые определяют выбор конкретного статистического инструментария.

Во-первых, объём доступных данных крайне мал: для каждого события мы располагаем всего десятью временными отсчётами. В таких условиях классические частотные методы, основанные на асимптотических свойствах оценок (например, кумулятивных сумм), имеют низкую мощность и не позволяют корректно оценить неопределённость положения τ . [1] Во-вторых, необходимо одновременно делать вывод как о дискретной величине — положении точки разладки τ , так и о непрерывных параметрах распределений $\boldsymbol{\theta}_1$, $\boldsymbol{\theta}_2$. В-третьих, принципиально важно не просто получить точечную оценку τ , но и охарактеризовать уверенность в её положении, поскольку при слабом сигнале точечная оценка может быть произвольной.

Этим требованиям в полной мере удовлетворяет байесовский подход к моделированию [1], [2]. В его рамках положение точки разладки τ рассматривается как дискретная случайная величина с априорным равномерным распределением на множестве всех допустимых моментов времени. Параметры распределений данных $\boldsymbol{\theta}_1$ и $\boldsymbol{\theta}_2$ снабжаются слабоинформативными априорными распределениями, отражающими априорные знания о разумных масштабах величин, но не навязывающими жёстких ограниче-

ний. Совместное апостериорное распределение $p(\tau, \theta_1, \theta_2 \mid \mathcal{D})$, где $\mathcal{D}$ означает совокупность наблюдаемых данных, получается по теореме Байеса и содержит всю доступную информацию о параметрах модели после учёта наблюдений.

Практическая реализация

Для практического вычисления апостериорных распределений в работе используется метод Монте-Карло по схеме марковской цепи (Markov chain Monte Carlo, МСМС) в реализации библиотеки PyMC. Моделирование МСМС позволяет получить набор выборочных значений параметров из апостериорного распределения, по которым затем строятся оценки интересующих величин и их байесовские доверительные интервалы.

Ключевым результатом для каждого исследуемого набора признаков и параметров профиля ПС является апостериорное распределение $p(\tau \mid \mathcal{D})$, которое показывает, в какой из дней, предшествующих землетрясению, с наибольшей вероятностью произошло изменение динамики сна. Концентрация апостериорной массы вблизи конкретного значения τ интерпретируется как свидетельство в пользу резкого, скачкообразного изменения характеристик ПС; напротив, широкое и пологое распределение указывает на отсутствие выраженного переключения или на плавный дрейф параметров, не укладывающийся в модель с единственной точкой разладки.

Данный подход, вдохновленный примером из [2] моделирования изменения интенсивности текстовых сообщений, обладает свойством естественной регуляризации: в случае, если данные не содержат информации об изменении (то есть параметры θ_1 и θ_2 фактически одинаковы), апостериорное распределение τ остаётся близким к равномерному, сигнализируя об отсутствии значимой разладки. Это свойство является критически важным в условиях малой выборки, где риск ложноположительного обнаружения структурного сдвига особенно высок.

В отличие от [2], где наблюдения представлены в дискретном виде и имеют соответствующие априорные правдоподобия, все наши наблюдения

имеют вещественные значения и, соответственно, должны иметь непрерывные правдоподобия. Это позволяет нам использовать No-U-Turn Sampler (NUTS) — адаптивное расширение алгоритма Hamiltonian Monte Carlo (HMC), специально разработанное для устранения необходимости ручной настройки длины траектории в фазовом пространстве вспомогательных импульсных переменных [5]. В отличие от классического HMC, где число шагов интегрирования гамильтоновой динамики задаётся пользователем и критически влияет на эффективность сэмплирования, NUTS рекурсивно удваивает дерево возможных состояний до тех пор, пока симулируемая траектория не начнёт разворачиваться вспять, автоматически определяя момент остановки по критерию отсутствия U-образного поворота. Математически установлено, что данный алгоритм сохраняет свойство обратимости и гарантирует геометрическую эргодичность для широкого класса целевых распределений [3], что обеспечивает его высокую эффективность при исследовании непрерывных вероятностных моделей, типичных для задач анализа геофизических временных рядов. Практическое применение NUTS в нашем случае дополнительно мотивировано тем обстоятельством, что непрерывные функции правдоподобия порождают гладкое апостериорное распределение, градиент которого может быть эффективно задействован гамильтоновой динамикой, обеспечивая подавление случайного блуждания и ускорение сходимости марковской цепи по сравнению с алгоритмами, основанными исключительно на случайных блужданиях.

Маргинализация τ

Как было отмечено ранее, параметр τ по своей природе является дискретной случайной величиной, принимающей значения в конечном множестве допустимых дней $\mathcal{T} = \{\tau_{\min}, \dots, \tau_{\max}\}$. Однако алгоритм NUTS, используемый нами для повышения эффективности сэмплирования, требует непрерывности и дифференцируемости логарифма апостериорной плотности по всем параметрам модели [5]. Это фундаментальное ограничение градиентных методов MCMC вынуждает нас отказаться от прямого сэмплиро-

вания τ как дискретного узла в графе вероятностной модели и прибегнуть к его маргинализации (аналитическому интегрированию) из совместного апостериорного распределения [6].

Пусть, $\boldsymbol{\theta}$ — полный набор всех непрерывных параметров модели (например, $\mu_1, \mu_2, \sigma_1, \sigma_2$, а также параметр формы распределения Стюдента, ν). Число возможных положений точки разладки конечно и составляет $n_\tau = |\mathcal{T}|$. Априорное распределение $p(\tau = k)$ для любого $k \in \mathcal{T}$ полагаем равномерным:

$$p(\tau = k) = \frac{1}{n_\tau}. \quad (6)$$

Для каждого кандидата $k \in \mathcal{T}$ мы вычисляем логарифмическую функцию правдоподобия при условии, что переключение произошло в день k :

$$\ell_k(\boldsymbol{\theta}) \equiv \log p(\mathcal{D} \mid \tau = k, \boldsymbol{\theta}). \quad (7)$$

Тогда дискретная переменная τ может быть проинтегрирована, и маргинальный логарифм правдоподобия для непрерывных параметров принимает вид:

$$\log p(\mathcal{D} \mid \boldsymbol{\theta}) = \log \sum_{k \in \mathcal{T}} p(\mathcal{D} \mid \tau = k, \boldsymbol{\theta}) p(\tau = k) = \log \sum_{k \in \mathcal{T}} \exp(\ell_k(\boldsymbol{\theta}) - \log n_\tau). \quad (8)$$

Вычислительная устойчивость данного выражения на практике обеспечивается применением стандартного приёма `log-sum-exp`, что позволяет избежать переполнения при экспоненцировании.

После исключения τ из пространства сэмплирования цепь Маркова генерирует выборку только из маргинального апостериорного распределения непрерывных параметров $p(\boldsymbol{\theta} \mid \mathcal{D})$. Однако информация о положении точки разладки не утрачивается и восстанавливается на этапе пост-обработки. Для каждого сэмплированного значения $\boldsymbol{\theta}^{(s)}$ мы вычисляем ненормированные логарифмические веса всех возможных дней переключения $\log w_k^{(s)} = \ell_k(\boldsymbol{\theta}^{(s)}) - \log n_\tau$. Нормируя их с помощью функции `softmax`,

получаем условные апостериорные вероятности положения разладки при данном значении непрерывных параметров:

$$\pi_k^{(s)} \equiv p(\tau = k \mid \mathcal{D}, \boldsymbol{\theta}^{(s)}) = \frac{\exp(\log w_k^{(s)})}{\sum_{j \in \mathcal{T}} \exp(\log w_j^{(s)})}. \quad (9)$$

Предельное апостериорное распределение интересующей нас дискретной величины $p(\tau = k \mid \mathcal{D})$ затем оценивается путём усреднения этих условных вероятностей по всем S итерациям МСМС:

$$\hat{p}_k = \frac{1}{S} \sum_{s=1}^S \pi_k^{(s)} \approx p(\tau = k \mid \mathcal{D}). \quad (10)$$

Такой подход аналогичен оценкам, полученным процедурой Рао-Блэквелла, и обладает меньшей дисперсией по сравнению с оценкой частот прямого сэмплирования τ . Полученные оценки $\hat{p}_k$ позволяют вычислить ключевые точечные характеристики положения разладки: апостериорное среднее $\mathbb{E}[\tau \mid \mathcal{D}] \approx \sum_{k \in \mathcal{T}} k \cdot \hat{p}_k$, а также моду апостериорного распределения $\tau_{\text{МАР}} = \arg \max_{k \in \mathcal{T}} \hat{p}_k$. Именно эти статистики используются нами далее для интерпретации результатов и определения наиболее вероятного момента предсейсмического изменения динамики сна.

3. Программная реализация

Программная реализация на языке Python, включающая в себя Jupyter-ноутбуки с результатами проведенных экспериментов, модулем функций создания и визуализации работы моделей МСМС, использующих главным образом библиотеку PyMC, а также модулем `seismic_pipeline`, реализующим препроцессинг и логику работы с временными рядами, расположена в гит-репозитории <https://github.com/Morpheyka/seismic-pipeline>.

Модуль `seismic_pipeline` является объектно-ориентированным наследником библиотеки методов машинного обучения Sci-Kit Learn. Он включает в себя разработанный сотрудниками НИТЦ нейротехнологий ЮФУ и рас-

ширенный нами модуль `mod`, который адаптирует стандартные инструменты (`Pipeline`, `GridSearchCV`, `Scaler` и пр.) под логику работы с временными рядами. Также в `seismic_pipeline` присутствует разработанный нами пакет препроцессоров гипнограм `seismo`, который позволяет вычислять последовательно (в конвейере) профиль сна и его признаки (среднее, размах и т.д.). Этот пакет является авторской разработкой, получившей государственную регистрацию: «Программа для построения конвейера обработчиков циклических данных и поиска оптимальных параметров прогнозных моделей машинного обучения», номер регистрации: 2026610377.

3.1. Логика работы с временными рядами

3.2. Предобработка

3.3. Байесовский метод

Рассмотренная выше вероятностная модель с единственной точкой разладки реализована в виде одной иерархической модели РумС: для каждого используемого признака задаются два набора параметров распределения наблюдений по чанкам времени — «до» и «после» предполагаемого момента τ . Конкретный перечень признаков и семейства правдоподобий задаются конфигурацией на уровне эксперимента (в Jupyter-ноутбуке — через словарь `parameter_selection`, см. листинг 1); программная сборка графа модели и запуск NUTS выполняются функциями модуля `rem_profiles_export_10`.

Для каждого имени признака из активного набора формируется словарь спецификаций: строка `likelihood` задаёт семейство правдоподобия (`normal`, `student_t`, `lognormal`, `gamma`, `beta`), а вложенные поля `mu_prior`, `sigma_prior`, `nu_prior`, `alpha_prior`, `beta_prior` описывают априоры для параметров этого семейства. Пользовательские значения объединяются с базовыми умолчаниями функцией `_parse_parameter_selection`, так что в модель попадает полностью развёрнутая конфигурация по каждому признаку. Априорные распределения создаются единообразно функцией `_build_prior`.

(листинг 2; полный текст — листинг 5): поддерживаются, в частности, нормальное, полуноормальное и полу- t распределения, экспоненциальное, логнормальное, а также конструкция `exponential_plus` ($\nu = z + \nu_{\text{off}}$, $z \sim \text{Exp}(\lambda)$). Для параметров с областью значений $(0, +\infty)$ используется флаг `positive_only`, ограничивающий допустимые типы априоров.

Имена случайных величин PyMC кодируют два режима с индексами `_1` и `_2` («до» и «после» разладки). Режим работы с τ задаётся аргументом `tau_mode`. При `tau_mode="discrete"` в модель включается узел $\tau \sim \text{Uniform}\{\tau_{\min}, \dots, \tau_{\max}\}$, а условные параметры правдоподобия для каждого чанка выбираются через `pm.math.switch` по условию на индекс чанка и значение τ . При `tau_mode="marginalized"` узел τ из пространства сэмплирования исключается: для каждого допустимого k строится маска чанков, относящихся к первому режиму, вычисляются суммы логарифмов правдоподобия по всем чанкам и признакам, что даёт вектор вкладов `loglik_by_tau`. Маргинальный логарифм правдоподобия по τ с равномерным априором $p(\tau = k) = 1/n_\tau$ (согласованным с (6)) добавляется в модель как потенциал с использованием численно устойчивого `log-sum-exp`, что соответствует (8). Нормализованные веса π_k при фиксированных непрерывных параметрах восстанавливаются через `softmax` и сохраняются как `tau_probs` (согласование с (9)); также формируются опорная решётка `tau_support` и среднее по распределению на решётке `tau_mean`. Итоговые оценки $\hat{p}_k \approx p(\tau = k \mid \mathcal{D})$ получаются усреднением по итерациям MCMC (реализовано в функции `tau_probabilities`), что соответствует (10). Фрагмент реализации маргинализации приведён в листинге 3; развёрнутый каркас функции `build_changepoint_model` — в листинге 6.

Вывод апостериорного распределения выполняется функцией `sample_model`. Вызывается `pm.sample` с алгоритмом NUTS; поддерживаются backend `pymc`, а также JAX-реализации `numpyro` и `blackjax`. Для последних требуется гладкая по всем сэмплируемым параметрам целевая функция, поэтому при выборе JAX-backend и заданном изначально дискретном τ сценарный интерфейс `run_variant` автоматически переключает модель на режим

`marginalized` (листинг 4). Полная процедура построения данных по чанкам, сборки модели и сэмплирования объединена в `run_variant`.

Листинг 1. Фрагмент задания семейств правдоподобий и априоров в ноутбук эксперимента

```
parameter_selection_mixed = {
    "mean": {
        "likelihood": "student_t",
        "mu_prior": {"dist": "normal", "mu": 0.5, "sigma": 0.25},
        "sigma_prior": {"dist": "halfnormal", "sigma": 0.2},
        "nu_prior": {"dist": "exponential_plus", "lam": 0.05,
                     "offset": 2.0},
    },
    # ... остальные признаки задаются аналогично
}
```

Листинг 2. Создание априорной случайной величины по текстовой спецификации (`_build_prior`)

```
def _build_prior(var_name: str, spec: dict, *, positive_only: bool =
    dist = str(spec.get("dist", "")).strip().lower()
    if dist == "normal":
        return pm.Normal(var_name, mu=float(spec.get("mu", 0.0)),
                          sigma=float(spec.get("sigma", 1.0)))
    if dist == "halfnormal":
        return pm.HalfNormal(var_name, sigma=float(spec.get("sigma",
    if dist == "exponential_plus":
        lam = float(spec.get("lam", 0.05))
        offset = float(spec.get("offset", 2.0))
        raw = pm.Exponential(f"{var_name}_raw", lam=lam)
        return pm.Deterministic(var_name, raw + offset)
```

Листинг 3. Маргинализация τ : потенциал с `logsumexp` и восстановление вероятностей на решётке

```
if tau_mode == "marginalized":
    log_w = loglik_by_tau - np.log(float(n_tau))
    pm.Potential("tau_marginalized_logp", pm.math.logsumexp(log_w))
    tau_probs = pm.Deterministic("tau_probs", pm.math.softmax(log_w))
    tau_support = pm.Deterministic(
        "tau_support",
        pt.as_tensor_variable(tau_values.astype(np.float64)),
    )
    pm.Deterministic("tau_mean", pm.math.sum(tau_probs * tau_support))
```

Листинг 4. Автоматический переход к `marginalized` при JAX-backend в сценарии `run_variant`

```
backend = str(nuts_backend).strip().lower()
if backend in {"numpyro", "blackjax"} and str(tau_mode).strip().lower()
    print(
        "JAX NUTS backend with discrete tau is unsupported; "
        "using tau_mode='marginalized'."
    )
tau_mode = "marginalized"
```

Литература

1. Jim Albert. *Bayesian Computation with R*. Springer, New York, NY, 2 edition, 2009.
2. Cameron Davidson-Pilon. *Bayesian Methods for Hackers: Probabilistic Programming and Bayesian Inference*. Addison-Wesley, 2015. URL <https://github.com/CamDavidsonPilon/Probabilistic-Programming-and-Bayesian-Methods-for-Hackers>. Includes the text-message change-point example.
3. Alain Durmus, Samuel Gruffaz, Miika Kailas, Eero Saksman, and Matti Vihola. On the convergence of dynamic implementations of Hamiltonian Monte Carlo and No U-turn samplers, 2023. URL <https://arxiv.org/abs/2307.03460>.
4. Guangzhan Fang, Yiwen Xia, Chunguang Zhang, Tiejun Liu, and Dezhong Yao. Optimized single electroencephalogram channel sleep staging in rats. *Laboratory Animals*, 44:312–322, 2010. doi: 10.1258/la.2010.009081.
5. Matthew D. Hoffman and Andrew Gelman. The no-U-turn sampler: Adaptively setting path lengths in Hamiltonian Monte Carlo. *Journal of Machine Learning Research*, 15:1593–1623, 2014. URL <https://www.jmlr.org/papers/v15/hoffman14a.html>.
6. Jinlin Lai, Javier Burroni, Hui Guan, and Daniel Sheldon. Automatically marginalized MCMC in probabilistic programming, 2023. URL <https://arxiv.org/abs/2302.00564>.
7. Anton Saevskiy, Natalia Suntsova, Peter Kosenko, Md Noor Alam, and Andrey Kostin. Open-source algorithm for automated vigilance state classification using single-channel electroencephalogram in rodents. *Sensors*, 25(3):921, 2025. doi: 10.3390/s25030921.
8. Vladyslav V. Vyazovskiy and Irene Tobler. Theta activity in the waking EEG is a marker of sleep propensity in the rat. *Brain Research*, 1050(1–2): 64–71, 2005. doi: 10.1016/j.brainres.2005.05.022.

Приложение

Ниже приведены расширенные листинги функций модуля `rem_profiles_exp` дополняющие краткие фрагменты в подразделе «Байесовский метод».

Листинг 5. Полная реализация `_build_prior`

```
def _build_prior(var_name: str, spec: dict, *, positive_only: bool =
    if not isinstance(spec, dict):
        raise ValueError(f"Prior spec for '{var_name}' must be a dict")
    dist = str(spec.get("dist", "")).strip().lower()
    if not dist:
        raise ValueError(f"Prior spec for '{var_name}' must include 'dist'")

    positive_dists = {"halfnormal", "halfstudentt", "exponential",
                      "lognormal", "exponential_plus"}
    if positive_only and dist not in positive_dists:
        raise ValueError(
            f"Prior '{var_name}' must be positive; use one of "
            f"{sorted(positive_dists)}, got '{dist}'."
        )

    if dist == "normal":
        return pm.Normal(var_name, mu=float(spec.get("mu", 0.0)),
                         sigma=float(spec.get("sigma", 1.0)))
    if dist == "halfnormal":
        return pm.HalfNormal(var_name, sigma=float(spec.get("sigma", 1.0)))
    if dist == "halfstudentt":
        return pm.HalfStudentT(
            var_name,
            nu=float(spec.get("nu", 4.0)),
            sigma=float(spec.get("sigma", 1.0)),
        )
    if dist == "exponential":
        return pm.Exponential(var_name, lam=float(spec.get("lam", 1.0)))
    if dist == "lognormal":
        return pm.LogNormal(
            var_name,
            mu=float(spec.get("mu", 0.0)),
            sigma=float(spec.get("sigma", 1.0)),
        )
    if dist == "exponential_plus":
        lam = float(spec.get("lam", 0.05))
        offset = float(spec.get("offset", 2.0))
        raw = pm.Exponential(f"{var_name}_raw", lam=lam)
```

```

        return pm.Deterministic(var_name, raw + offset)

    raise ValueError(
        f"Unsupported prior dist '{dist}' for '{var_name}'. "
        "Use one of: normal, halfnormal, halfstudentt, exponential, "
        "lognormal, exponential_plus."
    )

```

Листинг 6. Каркас `build_changepoint_model`: режимы τ и маргинализация (прочие ветви правдоподобия опущены)

```

def build_changepoint_model(
    group_data: dict,
    tau_lower: int = 2,
    tau_upper: int | None = None,
    parameter_selection: dict | None = None,
    tau_mode: str = "discrete",
):
    first_group = next(iter(group_data.values()))
    first_feat = next(iter(first_group.values()))
    n_group_chunks = first_feat.shape[1]

    if tau_upper is None:
        tau_upper = n_group_chunks
    active_features = {feat for features in group_data.values()
                       for feat in features.keys()}
    parameter_cfg = _parse_parameter_selection(parameter_selection,
                                                active_features)

    with pm.Model() as model:
        idx = np.arange(n_group_chunks)
        tau_values = np.arange(tau_lower, tau_upper + 1, dtype=np.int)
        n_tau = tau_values.size

        if tau_mode == "discrete":
            tau = pm.DiscreteUniform("tau", lower=tau_lower, upper=ta
            loglik_by_tau = None
            mask_before = None
        else:
            mask_before = (
                idx[None, :] < (tau_values[:, None] - 1)
            ).astype(float)
            loglik_by_tau = np.zeros(n_tau, dtype=float)

        for group_name, features in group_data.items():

```

```

        for feat_name, observed_df in features.items():
            observed = observed_df.to_numpy()
            spec = parameter_cfg[feat_name]
            likelihood = str(spec.get("likelihood", "normal")).st
            _ = (observed, spec, likelihood)
            # ... ветвление по likelihood; накопление loglik_by_tau

if tau_mode == "marginalized":
    log_w = loglik_by_tau - np.log(float(n_tau))
    pm.Potential("tau_marginalized_logp", pm.math.logsumexp(l
    tau_probs = pm.Deterministic("tau_probs", pm.math.softmax
    tau_support = pm.Deterministic(
        "tau_support",
        pt.as_tensor_variable(
            tau_values.astype(np.float64)
        ),
    )
    pm.Deterministic(
        "tau_mean",
        pm.math.sum(tau_probs * tau_support),
    )

return model

```