

МИНОБРНАУКИ РОССИИ

Федеральное государственное автономное образовательное
учреждение высшего образования
«Южный федеральный университет»

Институт математики, механики
и компьютерных наук им. И. И. Воровича

Кафедра алгебры и дискретной математики

Пономарев Матвей Борисович

**РАЗРАБОТКА МОДЕЛИ МАШИННОГО ОБУЧЕНИЯ ДЛЯ
РАСПОЗНАВАНИЯ ПРЕДВЕСТНИКОВ ЗЕМЛЕТРЯСЕНИЙ
НА ОСНОВЕ АНАЛИЗА БИОЭЛЕКТРИЧЕСКОЙ
АКТИВНОСТИ ГОЛОВНОГО МОЗГА ЖИВОТНОГО**

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
по направлению подготовки
01.03.02 – Прикладная математика и информатика

Научный руководитель –
доцент., к. т. н. Адигеев Михаил Георгиевич

Допущено к защите:
заведующий кафедрой _____ Штейнберг Б. Я.

Ростов-на-Дону – 2026

Оглавление

Постановка задачи	3
Введение	4
1. Материалы и методы.....	10
2. Поиск ширины аномального окна	16
3. Программная реализация	24
3.1. Предобработка	24
3.2. Байесовский метод.....	28
4. Полный перебор по метрике LOO-ELPD	32
5. Программная реализация полного перебора	41
Литература.....	46
Приложение.....	47

Постановка задачи

В постановке задачи коротко (по пунктам) указывается, что необходимо сделать в рамках работы. Раздел «Постановка задачи» должен соответствовать заданию на курсовую или выпускную квалификационную работу, подписанному научным руководителем.

Введение

Естественнонаучная постановка задачи

На данный момент не существует точной модели, описывающей физические процессы перед землетрясением (Родкин, 2011). Тем не менее, исследования продолжаются, так как накоплено много надежных данных о различных признаках приближающегося землетрясения: изменениях электромагнитных полей, химического состава вод и газов, деформациях поверхности и других (Cicerone et al., 2009; Geller, 2007; Ma et al., 2021; Chiodini et al., 2020).

По-видимому, некоторые из этих признаков способны улавливать животные. Известно множество случаев, когда незадолго до подземных толчков наблюдалось необычное поведение: собаки начинали громко лаять, кошки и собаки пытались убежать, крысы покидали норы, пчелы — ульи, а птицы издавали частые крики (Kirschvink, 2000). Также зафиксированы случаи, когда жабы покидали места своего обитания до завершения серии повторных толчков (Grant et al., 2011). В некоторых исследованиях даже численно показана связь между активностью мышей за день до землетрясения и изменениями геомагнитного поля (Yokoi et al., 2003).

С точки зрения эволюции такая чувствительность могла закрепиться, потому что одно крупное землетрясение (даже если оно случается раз в 50 поколений) способно уничтожить 10% и более популяции. Моделирование методом Монте-Карло показало высокую вероятность того, что способность чувствовать приближение катастрофы закреплялась в ходе естественного отбора (Kirschvink, 2000).

Известно, что реакция животных на предвестники землетрясений связана с состоянием стресса или повышенной тревоги. Стресс напрямую влияет на цикл сна и бодрствования, а также на общую активность (Rampin et al., 1991; Meerlo et al., 1997; Palma et al., 2000; Adrien et al., 1991). Согласно теории Ганса Селье (Selye, 1950), стресс — это общая реакция организма на вредные воздействия. Ее механизм связан с выбросом определенных

гормонов (кортикотропин-рилизинг-гормона, а затем глюкокортикоидов). Выделение этих гормонов также подчиняется суточным ритмам, что задает циклический характер активности у грызунов (Herman et al., 2016; Kalsbeek et al., 2012). Колебания уровня этих гормонов меняют структуру сна у крыс (Bradbury et al., 1998). При этом разные виды стресса приводят к разным изменениям в структуре сна — например, одни увеличивают долю быстрого сна, а другие — долю медленного (Rampin et al., 1991; Meerlo et al., 1997; Palma et al., 2000; Adrien et al., 1991; Sanford et al., 2010).

Сон млекопитающих достаточно хорошо изучен. В нем выделяют две основные фазы: быстрый сон (с быстрыми движениями глаз, REM) и медленный сон (Rytönen, 2011; Saevskiy, 2025; Kostin, 2019; Vyazovskiy, 2005; Lyamin, 2008). Для быстрого сна характерны низкоамплитудные высокочастотные колебания на электроэнцефалограмме и расслабление мышц. Эти две фазы циклически сменяют друг друга, причем медленный сон всегда предшествует быстрому. У грызунов сон, как правило, состоит из множества повторяющихся эпизодов в течение суток, причем спят они в основном в светлое время суток (Franken et al., 1999; Weber, Dan, 2016).

Исходя из вышесказанного, в данной работе ставится цель разработать и применить метод автоматического обнаружения изменений в динамике парадоксального сна крыс по данным непрерывной регистрации биоэлектрической активности мозга. Для этого решаются следующие задачи: построение вероятностной модели временного ряда с точкой разладки, реализация байесовского вывода о положении этой точки средствами вероятностного программирования, а также сравнение различных конфигураций модели по качеству предсказаний. Быстрый сон выбран в качестве целевого показателя как наиболее чувствительный к стрессу индикатор состояния животного.

Важно подчеркнуть, что данное исследование не направлено на построение предиктивной модели для прогнозирования землетрясений. Его основная цель — проверка научной гипотезы о существовании статистически значимой физиологической реакции крыс на геофизические процессы, сопровождающие подготовку сейсмического события. В рамках этой про-

верки решаются две ключевые задачи: 1) подтверждение гипотезы о наличии аномального паттерна в динамике парадоксального сна до и после землетрясения, отличающегося от фонового режима; 2) количественная оценка оптимальной ширины временного окна, в котором эта аномалия проявляется. Отдельное внимание уделяется не только периоду, предшествующему толчку (времени «предчувствия»), но и периоду после него — времени, за которое животное возвращается в нормальное физиологическое состояние.

Машинное обучение и анализ данных

Обращение к машинному обучению в описанной задаче представляется логичным продолжением: мы располагаем многомерным временным рядом физиологических показателей, которые, по-видимому, связаны с редкими внешними событиями, и стремимся выявить эту связь, не располагая строгой физической моделью. Вместе с тем особенности предметной области накладывают ряд жёстких ограничений, которые нельзя игнорировать при подборе и оценивании моделей.

Проблема сверхмалой выборки. Землетрясения достаточной силы, ощутимые в районе размещения лаборатории, происходят нечасто. Даже если мониторинг ведётся непрерывно, количество событий, приходящихся на интервал регистрации, исчисляется единицами или первыми десятками. Это ключевое затруднение: в отличие от стандартных постановок задач машинного обучения, мы лишены возможности опереться на тысячи или сотни образцов целевого явления. Многие производительные модели, в частности глубокие нейросети и ансамбли, относятся к разряду «чёрных ящиков» (Alan Turing Institute) и нуждаются в значительно более объёмных выборках, чтобы обучаться без переобучения. В нашей ситуации разумнее прибегнуть к методам, экономным по числу степеней свободы. Байесовские модели, опирающиеся на сильные априорные допущения, дают ещё одно преимущество — возможность естественным образом оценить неопределённость, порождённую скудостью данных (Šinkovec, 2022). В отличие от точечного прогноза, такая модель выдаёт распределение вероят-

ных значений параметров, а ширина этого распределения показывает меру нашей неуверенности.

Неоднородность данных. Обучающая и проверочная выборки в рассматриваемой задаче заведомо не удовлетворяют требованию независимости и одинаковой распределённости (i.i.d.). Мы имеем дело с непрерывным временным рядом, последовательные отсчёты которого сильно скоррелированы друг с другом [?]. Более того, условия, в которых собираются данные, не остаются постоянными: сезонная ритмика сказывается на поведении [?], с возрастом физиология особи меняется [?], возможен инструментальный дрейф регистрирующей аппаратуры [?]. Наконец, сами землетрясения различаются по магнитуде, удалённости от лаборатории, глубине гипоцентра и тектонической обстановке, следовательно, могут различаться и характеристики предвестников, доходящих до пункта наблюдения [?]. Как следствие, модель, удачно показавшая себя на одном временном отрезке, способна полностью потерять предсказательную силу на другом, если не принимать во внимание перечисленные источники вариативности [?]. Частичным выходом служат иерархические байесовские модели: в их структуру можно встроить параметры, описывающие и индивидуальные черты конкретного животного, и особенности отдельного события [?].

Специфика работы с временными рядами. Так как данные образуют временной ряд, прямое использование стандартных классификаторов или регрессионных методов, предполагающих независимость наблюдений, ведёт к некорректным выводам. Временная упорядоченность порождает автокорреляцию: если сегодня у крысы зарегистрирована аномально высокая доля быстрого сна, то и завтрашний показатель, скорее всего, отклонится от среднего просто вследствие инерционности физиологических процессов. Игнорирование этой зависимости приводит к ложной оценке значимости обнаруженных закономерностей. При кросс-валидации временных рядов нельзя прибегать к случайному разбиению на фолды — оно разрушает хронологию и открывает дорогу «утечке данных» из будущего, что выражается в неоправданно оптимистичных метриках (Bergmeir Benítez, 2012; scikit-learn Developers). Вместо этого следует использовать

схемы, сохраняющие временной порядок, такие как скользящий контроль с расширяющимся окном (forward-chaining), при котором обучение всегда опирается только на предшествующие наблюдения, а проверка — на последующие (RemNote Study Deck).

Проблема множественного тестирования. В ситуации, когда данных мало, а потенциальных предикторов (различные геофизические параметры, их лаги, частотные компоненты) много, возникает риск ложноположительных находок. Перебор большого числа гипотез без учета поправки на множественность почти гарантирует обнаружение статистически значимых, но содержательно пустых корреляций. Байесовский подход смягчает эту проблему, поскольку апостериорное распределение естественным образом штрафует сложные модели через маргинальное правдоподобие, а использование регуляризующих априорных распределений, таких как horseshoe prior или spike-and-slab prior, позволяет автоматически отсеивать неинформативные предикторы (Denti, 2021).

Интерпретируемость и научная ценность. В отличие от многих прикладных задач машинного обучения, где главный критерий — точность предсказания, в данной работе не менее важна интерпретируемость результата. Нас интересует не только сам факт обнаружения аномалии перед землетрясением, но и количественная оценка временного окна, в котором эта аномалия проявляется, направленность изменений и степень индивидуальной вариабельности. Байесовский вывод здесь предпочтительнее многих "черных ящиков" так как дает прямые вероятностные утверждения об интересующих величинах.

Таким образом, с учетом перечисленных ограничений, в данной работе мы фокусируемся на байесовских методах анализа временных рядов как на инструменте, позволяющем совместить обнаружение аномальных паттернов сна с корректным учетом неопределенности, порожденной малым объемом данных и их сложной временной структурой. Основное внимание уделяется проверке гипотезы о наличии устойчивого физиологического отклика и характеристике его временных свойств как до, так и после сейсмического события, а не построению предсказательной модели земле-

трясений.

1. Материалы и методы

В настоящем исследовании использованы материалы и методы, а также промежуточные результаты достижений исследовательской лаборатории разработки перспективных технологий краткосрочного сейсмопрогнозирования, учрежденной в рамках программы Стратегического академического лидерства Южного федерального университета (СП-11-24-02, КБК СП02/S4_0708 Приоритет_11, № НИОТКР 124060400026-7) на базе НИТЦ нейротехнологий ЮФУ при поддержке Фонда перспективных исследований (Договор от 23.12.2021 г. № 6/242/2022-2023AB) и совместно с КФ ФИЦ ЕГС РАН.

Экспериментальные животные и условия содержания

Эксперименты по получению сигнала интеркортикальной ЭЭГ проводились на базе Камчатского филиала Единой геофизической службы РАН (г. Петропавловск-Камчатский, станция «Институт»). Объектом исследования служили взрослые самцы крыс линии пасюк массой от 200 до 250 г. Животные содержались поодиночке в прозрачных пластиковых боксах размером $30 \times 30 \times 40$ см с перфорированными стенками. В помещении поддерживалась постоянная температура ($23 \pm 1^\circ\text{C}$) и фиксированный 12-часовой цикл освещения (12 ч свет / 12 ч темнота). Доступ к пище и воде был свободным. Все процедуры были одобрены комиссией по биоэтике Южного федерального университета.

Регистрация биоэлектрической активности

Для оценки состояний сна и бодрствования непрерывно регистрировалась электрическая активность коры больших полушарий (ЭКоГ) и гиппокампа (ЭСКоГ). Для этого сотрудники станции вживляли электроды животным под наркозом в область сенсомоторной коры и в поле СА1

Рис. 1. 5-секундная эпоха регистрируемого сигнала ЭЭГ крысы.

гиппокампа. Электроды соединялись с разъемом, который фиксировался на поверхности черепа. Регистрацию начинали не ранее чем через неделю после операции, чтобы исключить влияние восстановительного периода.

Запись сигналов велась с помощью 32-канального усилителя RBX2/32sp-r/32fp300 (Plexon Corp., США) и аналого-цифрового преобразователя L-ACRD (модель E 14-440). Частота оцифровки составляла 1 кГц по каждому каналу.

Раз в 24 часа суточная запись ЭЭГ выгружалась в объектное хранилище. Пример визуализации 5-секундной эпохи (1250 отсчетов) представлен на рисунке 1

Алгоритм классификации состояний сна и бодрствования

Для извлечения информации о функциональном состоянии животных из зарегистрированных сигналов использовался автоматический алгоритм стадирования, разработанный сотрудниками НИТЦ нейротехнологий ЮФУ и реализованный на языке Python. Алгоритм является упрощенной версией метода, описанного в работе [7](Saevski), и относит каждую эпоху записи к одному из трех состояний: бодрствование, медленный сон (МС) или парадоксальный сон (ПС). Процедура обработки состоит из следующих шагов:

- 1) Суточная запись сигналов разбивается на неперекрывающиеся эпохи длительностью 5 с.
- 2) Эпохи, содержащие высокоамплитудные артефакты (например, вызванные движением животного), исключаются из дальнейшего анализа.
- 3) Для каждой оставшейся эпохи с помощью быстрого преобразования Фурье вычисляются спектры мощности сигналов ЭКоГ и ЭСКоГ с раз-

решением по частоте 0.5 Гц.

- 4) **Детекция МС:** В спектре мощности ЭКоГ выделяется дельта-диапазон (2.5–5.5 Гц) [4](Fang2010). Суммарная мощность в этом диапазоне образует временной ряд, в котором методом гауссовых смесей выделяются две компоненты. Компонента с более высокой средней мощностью интерпретируется как медленный сон.
- 5) **Детекция ПС:** В спектре мощности ЭСКоГ выделяется тета-диапазон (5.5–8 Гц) [8](Vyazovskiy2005). Для каждой эпохи вычисляется отношение мощности тета-ритма к мощности дельта-ритма. В полученном ряду выделяются высокоамплитудные пики, которые маркируются как эпизоды парадоксального сна.
- 6) Результаты шагов 4 и 5 объединяются: эпохи, классифицированные как МС или ПС, получают соответствующие метки; все оставшиеся эпохи считаются бодрствованием.

Результатом работы алгоритма является гипнограмма — последовательность меток состояний для каждой 5-секундной эпохи на протяжении всей суточной записи. Именно гипнограмма служит исходным материалом для дальнейшего анализа связи структуры сна с сейсмической активностью.

Выборка сейсмических событий

Были использованы данные 14 сейсмических событий, произошедших в 2022-2025 годах; даты событий и номера крыс, используемых для анализа приведены в Таблице 1. Критериями отбора сейсмических событий служили инструментальная интенсивность (> 2 баллов) и доступность данных биоэлектрической активности мозга крысы на станции «Институт» (г. Петропавловск-Камчатский, Россия, 53.06° N, 158.61° E) за 8 дней до и 8 дней после сейсмического события. Здесь под инструментальной интенсивностью понимается оценка по пиковым значениям прошедших предвари-

тельную фильтрацию в полосе $[0.1; 10]$ Гц сигналов акселерометров во время землетрясения (по ГОСТ Р 57546–2017), на станции «Институт». Стоит обратить внимание, что для сейсмических событий 02.07.2025 и 20.07.2025 на станции присутствовало сразу 4 грызуна (R1, R2, R3, R4), доступность сигнала которых мы считаем достаточным для дальнейшего анализа.

Таблица 1. Выборка сейсмических событий

ИД крысы	Дата
R2	2022-11-07
R2	2022-11-18
R2	2023-04-03
R2	2023-04-11
R2	2023-04-18
R2	2023-04-21
R2	2023-05-03
R2	2023-05-09
R2	2024-09-30
R2	2024-10-29
R3	2025-01-23
R3	2025-03-14
R1	2025-07-02
R2	2025-07-02
R3	2025-07-02
R4	2025-07-02
R1	2025-07-20
R2	2025-07-20
R3	2025-07-20
R4	2025-07-20

Суточные профили парадоксального сна и их признаки

На основании результатов стадирования функционального состояния животных строились суточные профили парадоксального сна (ПС). Под суточным профилем понимается временной ряд, отражающий динамику доли времени, проведенного животным в состоянии ПС, вычисленной в

Рис. 2. Профиль парадоксального сна крысы.

пределах последовательных временных окон на протяжении одной суточной гипнограммы.

В общем виде профиль определяется двумя параметрами: шириной окна W и шагом смещения S . Выбор конкретных значений этих параметров представляет собой отдельную задачу, и их оптимальные значения для данного исследования еще предстоит определить. С одной стороны, слишком узкое окно приводит к излишней зашумленности профиля и появлению большого числа нулевых значений в тех интервалах, где эпизоды ПС просто не успевают реализоваться. С другой стороны, чрезмерно широкое окно сглаживает суточную динамику, скрывая потенциально важные детали поведения.

На рисунке 2 изображен пример нормального профиля парадоксального сна, полученного с использованием следующего набора параметров: ширина окна $W = 2$ часа, шаг $S = 2$ часа (непересекающиеся окна). При таком разбиении суточная запись описывается набором из 12 значений, что позволяет, с одной стороны, достаточно детально проследить циркадианный ритм животного (высокая доля ПС в светлую фазу, низкая — в темную), а с другой — получить приемлемую гладкость профиля без чрезмерного шума. В ходе исследования, при переходе к количественному анализу, параметры W и S будут уточнены в настоящей работе, в том числе с использованием формальных критериев оптимальности, таких как максимизация апостериорной вероятности модели или минимизация ошибки предсказания на отложенных данных.

Для компактного описания суточной динамики ПС и последующего статистического анализа вводятся несколько числовых характеристик, вычисляемых по профилю $P = \{p_1, p_2, \dots, p_N\}$, где p_i — доля ПС в i -м временном окне, а N — число окон в суточной записи.

Среднее значение профиля характеризует общий уровень ПС в течение рассматриваемого интервала — сутки, день или ночь — и опреде-

ляется как

$$\bar{P} = \frac{1}{N} \sum_{i=1}^N p_i. \quad (1)$$

Размах профиля характеризует контраст между наибольшей и наименьшей долей ПС и вычисляется по формуле

$$R = \max(P) - \min(P). \quad (2)$$

Этот показатель позволяет одной величиной описать выраженность циркадианного ритма: как правило, максимум профиля наблюдается в светлую фазу суток, когда у грызунов отмечается наибольшая длительность сна, а минимум приходится на тёмную фазу, соответствующую периоду бодрствования и активности. На рис. 3 (А и Б) приведён пример перехода от полных суточных профилей к значениям размаха.

В качестве характеристик стрессового состояния животного мы также рассматриваем **смещение** и **куртозис** профиля парадоксального сна, однако в дальнейшем будет показано, что эти метрики не обладают статистической значимостью для решаемой задачи.

Смещение профиля даёт количественную меру асимметрии распределения величин p_i относительно среднего и определяется стандартизованным третьим центральным моментом:

$$\gamma_1 = \frac{\frac{1}{N} \sum_{i=1}^N (p_i - \bar{P})^3}{\left(\frac{1}{N} \sum_{i=1}^N (p_i - \bar{P})^2 \right)^{3/2}}. \quad (3)$$

Положительное смещение свидетельствует о том, что профиль содержит сравнительно мало высоких значений (эпизодов ПС) на фоне в основном низких; отрицательное — напротив, указывает на наличие отдельных провалов при общем высоком фоне.

Эксцесс (куртозис) описывает остроту вершины распределения, иными словами — степень сосредоточенности значений около среднего в сопоставлении с нормальным распределением. Выборочный эксцесс зада-

ётся выражением

$$\gamma_2 = \frac{\frac{1}{N} \sum_{i=1}^N (p_i - \bar{P})^4}{\left(\frac{1}{N} \sum_{i=1}^N (p_i - \bar{P})^2 \right)^2} - 3. \quad (4)$$

Вычитание тройки нормирует показатель так, что для нормального распределения $\gamma_2 = 0$. Положительные величины означают утяжелённые хвосты и/или более выраженный пик, отрицательные — более равномерную форму распределения по диапазону.

Перечисленные характеристики вычисляются не только для полного суточного профиля (24-часовой отрезок), но и отдельно для его светлой и тёмной частей. Такое разделение даёт возможность разграничить вклад интервалов покоя и активности в результирующие показатели и, потенциально, выявить дифференцированное действие геофизических факторов: например, изменение размаха может вызываться в первую очередь падением доли ПС именно в светлую фазу, тогда как ночной сон сохраняется без изменений. Аналогичное соображение справедливо и для остальных метрик.

Таким образом, каждые сутки наблюдений описываются набором из нескольких чисел (среднее, размах, смещение, эксцесс) для полного профиля, а также для его дневного и ночного фрагментов. Эти значения, оптимальный набор которых мы определим в ходе исследования, формируют многомерный временной ряд, который в дальнейшем анализируется на предмет связи с сейсмическими событиями и их предвестниками.

2. Поиск ширины аномального окна

Поиск точки разладки

Целью этой главы является проверка гипотезы о существовании статистически значимого изменения характеристик парадоксального сна (ПС) у крыс в период, непосредственно предшествующий сейсмическому событию, определение их оптимального набора и количественная оценка вре-

менной ширины окна, в котором данная аномалия проявляется.

Для достижения этой цели в рамках исследования решаются следующие задачи:

1. Построение многомерных временных рядов признаков ПС (среднее, размах, смещение, эксцесс за день/ночь/сутки) для интервалов длительностью 8 суток, непосредственно предшествующих каждому из зарегистрированных землетрясений.
2. Разработка статистического метода, позволяющего обнаруживать момент резкого изменения свойств (точку разладки, changepoint) в построенных временных рядах в условиях крайне малого числа наблюдений.
3. Применение выбранного метода к полученным данным и идентификация временного положения точки разладки τ относительно момента основного толчка.
4. Оценка неопределённости положения τ и амплитуды изменения параметров ПС, а также проверка робастности выводов относительно индивидуальных особенностей животных и параметров предварительной обработки сигнала.

Формирование временных рядов и постановка задачи о разладке

Для каждого из E сейсмических событий, удовлетворяющих критериям отбора (Таблица 1), и для каждой крысы, по которой доступна непрерывная гипнограмма за соответствующий период, строится индивидуальный временной ряд. Под временным рядом понимается последовательность значений признаков ПС, вычисленных для последовательных суток на интервале в 10 дней, непосредственно предшествующих моменту землетрясения. Описанная ниже процедура формирования временных рядов и их

предобработки разработана автором с учётом специфики решаемой задачи и доступных данных.

Обозначим момент основного толчка через t_{event} . Анализируется предшествующий промежуток, включающий дискретные отсчёты $t \in \{1, 2, \dots, N\}$, где $N = 8$ отвечает количеству изучаемых суток. Для каждого дня t и каждой особи j строится вектор показателей $\mathbf{x}_t^{(j)}$, описывающий профиль ПС за соответствующую дату. В типовом случае этот вектор охватывает следующие характеристики, рассчитываемые как для полной суточной записи, так и отдельно для светлого и тёмного периодов:

- среднюю долю ПС $\bar{P}_t$;
- размах профиля R_t ;
- смещение $\gamma_{1,t}$;
- эксцесс $\gamma_{2,t}$.

Такой подход позволяет поставить в соответствие каждому из восьми дней, предшествующих толчку, набор физиологических параметров сна животного и тем самым получить многомерный временной ряд по каждому событию.

Поскольку между особями наблюдаются значительные отличия в абсолютном уровне показателей сна (например, у одной крысы средняя доля ПС может быть заметно выше, чем у другой, и циркадианные колебания имеют разную амплитуду), объединение исходных значений в общую выборку без предварительной обработки некорректно. Задача состоит не в сравнении абсолютных величин, а в обнаружении качественного изменения динамики ПС. По этой причине перед моделированием применяется минимаксное масштабирование (min-max scaling) каждого 8-дневного профиля в интервал $[0, 1]$, реализованное стандартными средствами библиотеки `scikit-learn` [?]. Нормировка проводится независимо для каждого животного и каждого сейсмического события, что снимает влияние индивидуального масштаба разброса, но сохраняет относительный ход временной динамики в пределах анализируемого окна.

Основная статистическая задача, решаемая в данном разделе, заключается в поиске точки разладки (changepoint) — момента времени τ , разделяющего весь 8-дневный интервал на два качественно различных участка: фоновый период и период аномальных значений, вызванных, предположительно, воздействием предвестников землетрясения. Следуя стандартной параметризации байесовских changepoint-моделей [2?], мы предполагаем, что наблюдения $\mathbf{x}_t$ порождаются вероятностным распределением, параметры которого могут изменяться в некоторый неизвестный момент τ :

$$\mathbf{x}_t \sim \begin{cases} p(\mathbf{x}_t \mid \boldsymbol{\theta}_1), & \text{если } t < \tau, \\ p(\mathbf{x}_t \mid \boldsymbol{\theta}_2), & \text{если } t \geq \tau, \end{cases} \quad (5)$$

где $\boldsymbol{\theta}_1$ и $\boldsymbol{\theta}_2$ — векторы параметров распределения до и после точки разладки соответственно, а сам момент τ также подлежит оцениванию по данным.

Выбор метода оценивания

Задача обнаружения точки разладки в коротких временных рядах обладает рядом особенностей, которые определяют выбор конкретного статистического инструментария.

Во-первых, объём доступных данных крайне мал: для каждого события мы располагаем всего восемью временными отсчётами. В таких условиях классические частотные методы, основанные на асимптотических свойствах оценок (например, кумулятивных сумм), имеют низкую мощность и не позволяют корректно оценить неопределённость положения τ . [1] Во-вторых, необходимо одновременно делать вывод как о дискретной величине — положении точки разладки τ , так и о непрерывных параметрах распределений $\boldsymbol{\theta}_1$, $\boldsymbol{\theta}_2$. В-третьих, принципиально важно не просто получить точечную оценку τ , но и охарактеризовать уверенность в её положении, поскольку при слабом сигнале точечная оценка может быть произвольной.

Этим требованиям в полной мере удовлетворяет байесовский подход к моделированию [1], [2]. В его рамках положение точки разладки τ рас-

сматривается как дискретная случайная величина с априорным равномерным распределением на множестве всех допустимых моментов времени. Параметры распределений данных θ_1 и θ_2 снабжаются слабоинформативными априорными распределениями, отражающими априорные знания о разумных масштабах величин, но не навязывающими жёстких ограничений. Совместное апостериорное распределение $p(\tau, \theta_1, \theta_2 \mid \mathcal{D})$, где $\mathcal{D}$ обозначает совокупность наблюдаемых данных, получается по теореме Байеса и содержит всю доступную информацию о параметрах модели после учёта наблюдений.

Практическая реализация

Для практического вычисления апостериорных распределений в работе используется метод Монте-Карло по схеме марковской цепи (Markov chain Monte Carlo, МСМС) в реализации библиотеки PyMC. Моделирование МСМС позволяет получить набор выборочных значений параметров из апостериорного распределения, по которым затем строятся оценки интересующих величин и их байесовские доверительные интервалы.

Ключевым результатом для каждого исследуемого набора признаков и параметров профиля ПС является апостериорное распределение $p(\tau \mid \mathcal{D})$, которое показывает, в какой из дней, предшествующих землетрясению, с наибольшей вероятностью произошло изменение динамики сна. Концентрация апостериорной массы вблизи конкретного значения τ интерпретируется как свидетельство в пользу резкого, скачкообразного изменения характеристик ПС; напротив, широкое и пологое распределение указывает на отсутствие выраженного переключения или на плавный дрейф параметров, не укладывающийся в модель с единственной точкой разладки.

Данный подход, вдохновленный примером из [2] моделирования изменения интенсивности текстовых сообщений, обладает свойством естественной регуляризации: в случае, если данные не содержат информации об изменении (то есть параметры θ_1 и θ_2 фактически одинаковы), апостериорное распределение τ остаётся близким к равномерному, сигнализируя об

отсутствии значимой разладки. Это свойство является критически важным в условиях малой выборки, где риск ложноположительного обнаружения структурного сдвига особенно высок.

В отличие от работы [2], где наблюдения носят дискретный характер и подразумевают дискретные вероятностные модели, в нашем случае все измерения выражены вещественными числами и, следовательно, требуют непрерывных функций правдоподобия.

Это обстоятельство даёт нам возможность применить No-U-Turn Sampler (NUTS) — адаптивную модификацию алгоритма Hamiltonian Monte Carlo (НМС), созданную именно для того, чтобы избавить исследователя от ручного подбора длины траектории в фазовом пространстве вспомогательных импульсных переменных [5]. Если в классическом НМС число шагов интегрирования гамильтоновой динамики назначается пользователем и напрямую определяет качество сэмплирования, то NUTS последовательно наращивает дерево потенциальных состояний до момента, когда моделируемая траектория не начинает возвращаться назад; момент остановки определяется автоматически по критерию отсутствия U-образного поворота.

Теоретически доказано, что данный алгоритм остаётся обратимым и обеспечивает геометрическую скорость сходимости для обширного класса целевых распределений [3], что обуславливает его высокую результативность при изучении непрерывных вероятностных моделей, характерных для анализа геофизических временных рядов.

Выбор NUTS в нашей работе продиктован ещё и тем, что непрерывные функции правдоподобия формируют гладкую апостериорную плотность, градиент которой эффективно используется гамильтоновой динамикой, подавляя тем самым случайные блуждания и ускоряя сходимость марковской цепи по сравнению с алгоритмами, опирающимися лишь на случайное блуждание.

Маргинализация τ

Параметр τ по своей природе является дискретной случайной величиной, принимающей значения в конечном множестве допустимых дней $\mathcal{T} = \{\tau_{\min}, \dots, \tau_{\max}\}$. Однако алгоритм NUTS, используемый нами для повышения эффективности сэмплирования, требует непрерывности и дифференцируемости логарифма апостериорной плотности по всем параметрам модели [5]. Это фундаментальное ограничение градиентных методов МСМС исключает прямое сэмплирование τ как дискретного узла в графе вероятностной модели.

Для преодоления данного ограничения мы применили метод маргинализации дискретных параметров, предложенный в [6] и реализованный в библиотеке РумС. Идея метода состоит в аналитическом интегрировании дискретной переменной из совместного апостериорного распределения, что позволяет получить непрерывную целевую функцию, пригодную для градиентного сэмплирования. Ниже мы воспроизводим соответствующие формулы применительно к обозначениям нашей задачи.

Пусть $\boldsymbol{\theta}$ — полный набор всех непрерывных параметров модели ($\mu_1, \mu_2, \sigma_1, \sigma_2$, а также параметр формы распределения Стьюдента ν). Число возможных положений точки разладки конечно и составляет $n_\tau = |\mathcal{T}|$. Следуя [6], априорное распределение $p(\tau = k)$ для любого $k \in \mathcal{T}$ полагаем равномерным:

$$p(\tau = k) = \frac{1}{n_\tau}. \quad (6)$$

Для каждого кандидата $k \in \mathcal{T}$ вычисляется логарифмическая функция правдоподобия при условии, что переключение произошло в день k :

$$\ell_k(\boldsymbol{\theta}) \equiv \log p(\mathcal{D} \mid \tau = k, \boldsymbol{\theta}). \quad (7)$$

Тогда дискретная переменная τ может быть проинтегрирована, и маргинальный логарифм правдоподобия для непрерывных параметров при-

нимает стандартный вид [6]:

$$\log p(\mathcal{D} \mid \boldsymbol{\theta}) = \log \sum_{k \in \mathcal{T}} p(\mathcal{D} \mid \tau = k, \boldsymbol{\theta}) p(\tau = k) = \log \sum_{k \in \mathcal{T}} \exp(\ell_k(\boldsymbol{\theta}) - \log n_\tau). \quad (8)$$

Вычислительная устойчивость данного выражения на практике обеспечивается применением стандартного приёма `log-sum-exp`, что позволяет избежать переполнения при экспоненцировании.

После исключения τ из пространства сэмплирования цепь Маркова генерирует выборку только из маргинального апостериорного распределения непрерывных параметров $p(\boldsymbol{\theta} \mid \mathcal{D})$. Информация о положении точки разладки восстанавливается на этапе пост-обработки с использованием формул, также описанных в [6]. Для каждого сэмплированного значения $\boldsymbol{\theta}^{(s)}$ вычисляются ненормированные логарифмические веса всех возможных дней переключения $\log w_k^{(s)} = \ell_k(\boldsymbol{\theta}^{(s)}) - \log n_\tau$. Нормируя их с помощью функции `softmax`, получаем условные апостериорные вероятности положения разладки при данном значении непрерывных параметров:

$$\pi_k^{(s)} \equiv p(\tau = k \mid \mathcal{D}, \boldsymbol{\theta}^{(s)}) = \frac{\exp(\log w_k^{(s)})}{\sum_{j \in \mathcal{T}} \exp(\log w_j^{(s)})}. \quad (9)$$

Предельное апостериорное распределение интересующей нас дискретной величины $p(\tau = k \mid \mathcal{D})$ оценивается путём усреднения этих условных вероятностей по всем S итерациям МСМС:

$$\hat{p}_k = \frac{1}{S} \sum_{s=1}^S \pi_k^{(s)} \approx p(\tau = k \mid \mathcal{D}). \quad (10)$$

Данный подход аналогичен оценкам, получаемым процедурой Рао–Блэквелла, и обладает меньшей дисперсией по сравнению с оценкой частот прямого сэмплирования τ . Полученные оценки $\hat{p}_k$ позволяют вычислить ключевые точечные характеристики положения разладки: апостериорное среднее $\mathbb{E}[\tau \mid \mathcal{D}] \approx \sum_{k \in \mathcal{T}} k \cdot \hat{p}_k$, а также моду апостериорного распре-

ления $\tau_{\text{MAP}} = \arg \max_{k \in \mathcal{T}} \hat{p}_k$. Именно эти статистики используются нами далее для интерпретации результатов и определения наиболее вероятного момента предсейсмического изменения динамики сна.

3. Программная реализация

Программная реализация на языке Python включает в себя Jupyter-ноутбуки с результатами проведённых экспериментов, модуль функций для создания и визуализации байесовских моделей на базе библиотеки PyMC, а также модуль `seismic_pipeline`, реализующий препроцессинг и логику работы с временными рядами. Исходный код размещён в репозитории <https://github.com/Morpheyka/seismic-pipeline>.

Модуль `seismic_pipeline` является объектно-ориентированной надстройкой над библиотекой `scikit-learn`. Он включает в себя разработанный сотрудниками НИТЦ нейротехнологий ЮФУ и расширенный нами пакет `mod`, который адаптирует стандартные инструменты (`Pipeline`, `GridSearchCV`, `Scaler` и др.) к специфике временных рядов, а также разработанный нами пакет препроцессоров гипнограмм `seismo`, позволяющий вычислять в конвейерном режиме профили парадоксального сна и их числовые характеристики (среднее, размах, смещение, эксцесс). Пакет `seismo` является авторской разработкой, получившей государственную регистрацию: «Программа для построения конвейера обработчиков циклических данных и поиска оптимальных параметров прогнозных моделей машинного обучения», номер регистрации: 2026610377.

3.1. Предобработка

На вход программного конвейера подаются гипнограммы — последовательности меток функционального состояния животного для каждой 5-секундной эпохи суточной записи, полученные алгоритмом, описанным в разделе «Материалы и методы». Гипнограмма кодирует три состояния: бодрствование (0), медленный сон (1) и парадоксальный сон (2). Для каж-

дого сейсмического события из таблицы 1 и каждой крысы, по которой доступна непрерывная запись, формируется окно из $N = 8$ последовательных календарных суток, непосредственно предшествующих моменту основного толчка.

Построение профиля парадоксального сна

Ключевой процедурой предобработки служит перевод дискретной гипнограммы в непрерывный профиль парадоксального сна (ПС). Вычисления выполняются методом `_fraction` модуля `REMProfileCalculatorYt` и сводятся к расчёту доли эпох ПС внутри скользящего временного окна.

Рассмотрим гипнограмму как одномерный массив меток $h[0], h[1], \dots, h[M - 1]$, где M — общее число 5-секундных интервалов в суточной записи. Введём ширину окна W (в часах) и шаг S (в часах). Количество эпох, укладывающихся в одно окно, задаётся выражением

$$N_{\text{окна}} = \frac{3600}{\Delta t} \cdot W, \quad (11)$$

где $\Delta t = 5$ с — продолжительность одной эпохи. Шаг смещения, выраженный в эпохах, составляет $N_{\text{шага}} = \frac{3600}{\Delta t} \cdot S$.

Окно продвигается вдоль гипнограммы, начиная с `start = 0`, и останавливается, как только `start + Nокна` превышает M . В каждой позиции окна подсчитывается доля интервалов, размеченных как парадоксальный сон (метка 2):

$$p_{\text{ПС}} = 100 \cdot \frac{\#\{h[i] = 2 \mid \text{start} \leq i < \text{start} + N_{\text{окна}}\}}{N_{\text{окна}}}, \quad (12)$$

где символ $\#$ обозначает мощность множества.

Формирование 8-дневных векторов признаков

Для каждого зарегистрированного землетрясения и каждой подопытной особи строится общий вектор путём конкатенации суточных профилей ПС за все 8 суток, предшествующих сейсмическому событию. При $W = 6$ ч и $S = 1$ ч итоговая длина вектора равна $8 \times 19 = 152$ отсчётов. Конкатенация производится над уже вычисленными значениями REM%, а не над исходными гипнограммами. Это обеспечивает одинаковый вклад каждой календарной даты в результирующий вектор вне зависимости от небольших расхождений в продолжительности суточной записи, и одновременно сохраняет естественную суточную ритмику.

Если хотя бы для одних суток из восьми требуемая гипнограмма не обнаружена ни в кэше, ни в локальном файловом хранилище, всё событие целиком удаляется из выборки (флаг `drop_incomplete_events = True`). Столь строгое правило диктуется устройством модели: единственный пропуск делает невозможным надёжную локализацию момента разладки τ , поскольку временной ряд теряет непрерывность.

Нормировка и разбиение на временные чанки

Абсолютные значения доли ПС заметно различаются у разных животных (так, одна крыса может находиться в ПС в среднем 15% времени, а другая — 25%), поэтому смешивать сырые отсчёты в общую выборку некорректно. Чтобы убрать индивидуальный масштаб колебаний, каждый 8-дневный вектор подвергается минимаксной нормировке (min-max scaling) в интервал $[0, 1]$:

$$\tilde{p}_i = \frac{p_i - \min(\mathbf{p})}{\max(\mathbf{p}) - \min(\mathbf{p})}, \quad (13)$$

где $\mathbf{p} = (p_1, \dots, p_{240})$ — исходный набор значений REM% для одного события и одной особи. Нормировка проводится отдельно для каждой пары «событие–крыса», что позволяет сохранить форму временного хода внутри окна.

Нормированный вектор нарезается на K последовательных времен-

ных чанков приблизительно одинаковой длины. В ходе экспериментов опробованы два значения: $K = 8$ (чанк отвечает примерно целым суткам) и $K = 16$ (чанк охватывает около половины суток). При разбивке 152-точечного вектора на K частей базовый размер чанка составляет $\lfloor 152/K \rfloor$; остаток $152 \bmod K$ элементов раскладывается по чанкам поровну, причём добавление лишней точки начинается с чётных позиций.

Для каждого чанка $j = 1, \dots, K$ вычисляется вектор описательных статистик: среднее значение $\bar{x}_j$, размах $R_j = \max(\mathbf{x}_j) - \min(\mathbf{x}_j)$, стандартное отклонение s_j , смещение $\gamma_{1,j}$ и эксцесс $\gamma_{2,j}$. Таким образом, каждое сейсмическое событие описывается матрицей размера $K \times F$, где F — число выбранных статистик. Именно эти статистики, агрегированные по всем событиям, подаются на вход байесовской модели разладки.

Программная организация препроцессинга

Описанный конвейер предобработки реализован в виде набора функций модуля `rem_profiles_export_10days_lib.py` и вызывается из Jupyter-ноутбука эксперимента. Полный цикл включает три этапа:

- 1) Функция `export_rem_profiles_10days_cached_only` загружает гипнограммы из кэша/локального хранилища, вычисляет суточные профили ПС методом `REMProfileCalculatorYt._fraction`, конкатенирует их в 8-дневные векторы и сохраняет результат в CSV-файл.
- 2) Функция `prepare_model_data` загружает сохранённый CSV, применяет минимаксную нормировку и исключает события, помеченные как выпадающие (при необходимости).
- 3) Функция `compute_chunk_feature_map` выполняет разбиение нормированных векторов на чанки и вычисляет описательные статистики каждого чанка.

Все три этапа объединены в высокоуровневую функцию `run_variant`, которая принимает параметры предобработки (`rem_profile_params`, число чанков `n_chunks`, перечень активных статистик `feature_selection`) и

возвращает матрицу признаков, готовую к подаче в модель. Такая модульная организация позволяет гибко перебирать конфигурации предобработки (ширину окна, шаг, степень дробления чанков, набор статистик) без изменения кода, что существенно ускорило цикл экспериментов.

3.2. Байесовский метод

Описанная в разделе 2 вероятностная модель с единственной точкой разладки реализована в виде гибкого конструктора вероятностного графа на базе библиотеки PyMC. Для каждого целевого признака из активного набора динамически формируются два комплекта латентных параметров — для периода «до» предполагаемого момента переключения τ и «после» него. Конкретный перечень признаков и семейства правдоподобий задаются декларативно на уровне эксперимента (в Jupyter-ноутбуке — через словарь `parameter_selection`, см. листинг 1); программная сборка графа и запуск сэмплирования инкапсулированы в функции `build_changepoint_model` и `sample_model` модуля `rem_profiles_export_10days_lib.py`.

Конфигурирование модели

Гибкость модели обеспечивается декларативным способом её описания. Для каждого имени признака формируется словарь спецификаций: поле `likelihood` задаёт семейство правдоподобия (`normal`, `student_t`, `lognormal`, `gamma`, `beta`), а вложенные поля `mu_prior`, `sigma_prior`, `nu_prior` и другие описывают априорные распределения для параметров этого семейства.

Листинг 1. Фрагмент задания семейств правдоподобий и априоров в ноутбуке эксперимента

```
parameter_selection_mixed = {
    "mean": {
        "likelihood": "student_t",
        "mu_prior": {
            "dist": "normal",
            "mu": 0.5,
            "sigma": 0.25
```

```

    },
    "sigma_prior": {
        "dist": "halfnormal",
        "sigma": 0.2
    },
    "nu_prior": {
        "dist": "exponential_plus",
        "lam": 0.05,
        "offset": 2.0
    },
},
# ... остальные признаки задаются аналогично
}

```

Априорные распределения создаются единообразно функцией `_build_prior` (листинг 2; полный текст — листинг 4). Поддерживаются нормальное, полунормальное и полу- t распределения, экспоненциальное, логнормальное, а также конструкция `exponential_plus` ($\nu = z + \nu_{\text{off}}$, $z \sim \text{Exp}(\lambda)$), предназначенная для задания положительных параметров со смещённым от нуля носителем.

Листинг 2. Создание априорной случайной величины по текстовой спецификации (`_build_prior`)

```

def _build_prior(var_name: str, spec: dict, *,
                 positive_only: bool = False):
    dist = str(spec.get("dist", "")).strip().lower()
    if dist == "normal": return pm.Normal(
        var_name, mu=float(spec.get("mu", 0.0)),
        sigma=float(spec.get("sigma", 1.0)))
    if dist == "halfnormal": return pm.HalfNormal(
        var_name, sigma=float(spec.get("sigma", 1.0)))
    if dist == "exponential_plus":
        lam = float(spec.get("lam", 0.05))
        offset = float(spec.get("offset", 2.0))
        raw = pm.Exponential(
            f"{var_name}_raw", lam=lam)
        return pm.Deterministic(var_name, raw + offset)
    # ... остальные типы априоров обрабатываются
    # аналогично

```

Маргинализация дискретного параметра τ

Центральной методической особенностью программной реализации является способ учёта дискретной природы точки разладки τ . В терминах вероятностного графа РумС параметр τ — это целочисленная случайная величина с конечным числом возможных значений. Однако алгоритм NUTS, используемый нами для повышения эффективности сэмплирования, требует непрерывности и дифференцируемости логарифма апостериорной плотности по всем параметрам модели [5], что исключает прямое сэмплирование дискретных узлов.

Для преодоления этого ограничения в работе применена маргинализация τ — его аналитическое интегрирование из совместного апостериорного распределения [6]. В программной реализации каждое сейсмическое событие представлено набором из K последовательных временных чанков, пронумерованных индексом $t = 1, 2, \dots, K$. Точка разладки интерпретируется как номер чанка, начиная с которого распределение данных меняется: при $t < \tau$ наблюдения описываются параметрами $\boldsymbol{\theta}_1$, а при $t \geq \tau$ — параметрами $\boldsymbol{\theta}_2$ (формула (5)).

Для каждого кандидата $k \in \mathcal{T}$ строится бинарная маска $\mathbf{m}^{(k)} \in \{0, 1\}^K$ такая, что $m_t^{(k)} = 1$ при $t < k$ и $m_t^{(k)} = 0$ иначе. Тогда логарифм правдоподобия всего окна при фиксированном k принимает вид

$$\ell_k(\boldsymbol{\theta}) = \sum_{t=1}^{k-1} \log p(\mathbf{x}_t \mid \boldsymbol{\theta}_1) + \sum_{t=k}^K \log p(\mathbf{x}_t \mid \boldsymbol{\theta}_2), \quad (14)$$

что в программной реализации записывается как поэлементное произведение маски на вектор логарифмов правдоподобия с последующим суммированием по чанкам. Здесь $\boldsymbol{\theta}$ обозначает совокупность всех непрерывных параметров модели ($\mu_1, \mu_2, \sigma_1, \sigma_2$ и, в случае распределения Стьюдента, ν). Маргинальный логарифм правдоподобия по τ с равномерным априором $p(\tau = k) = 1/|\mathcal{T}|$ добавляется в модель как потенциал с использованием численно устойчивой операции `log-sum-exp` (формула (8)), что исключает τ из пространства сэмплирования и делает весь граф непрерывным и

дифференцируемым.

Фрагмент реализации маргинализации приведён в листинге 3; развёрнутый каркас функции `build_changepoint_model` — в листинге 5.

Листинг 3. Маргинализация τ : потенциал с `logsumexp` и восстановление вероятностей на решётке

```
# Для каждого k строим mask_before[t] = 1 при t < k,
# вычисляем loglik_by_tau по всем k и признакам,
# затем:
log_w = loglik_by_tau - np.log(float(n_tau))

pm.Potential("tau_marginalized_logp", pm.math.logsumexp(log_w))

tau_probs=pm.Deterministic("tau_probs",pm.math.softmax(log_w))

tau_support=pm.Deterministic("tau_support",
                             pt.as_tensor_variable(tau_values.astype(np.float64)),)

pm.Deterministic("tau_mean", pm.math.sum(tau_probs*tau_support))
```

Нормализованные веса π_k при фиксированных непрерывных параметрах восстанавливаются через `softmax` и сохраняются как детерминированная переменная `tau_probs` (согласование с (9)); также формируются опорная решётка `tau_support` и апостериорное среднее `tau_mean` как скалярное произведение π_k на значения решётки. Итоговые оценки апостериорного распределения $p(\tau = k \mid \mathcal{D})$ вычисляются усреднением сохранённых условных вероятностей $\pi_k^{(s)}$ по всем S итерациям МСМС, что соответствует формуле (10) и обладает меньшей дисперсией по сравнению с оценкой частот прямого сэмплирования τ .

Сэмплирование и вычислительные аспекты

Вывод апостериорного распределения выполняется функцией `sample_model` с использованием алгоритма NUTS. Помимо классического бэкенда `pmc`, реализована поддержка JAX-совместимых сэмплеров `numpyro` и `blackjax`, что позволяет задействовать высокопроизводительные градиентные вычисления на GPU/TPU без изменения пользовательской конфи-

гурации эксперимента. Маргинализация τ является обязательной при работе с JAX-бэкендами, так как последние принципиально не поддерживают дискретные случайные величины в графе; для классического бэкенда `numpy` она также используется как основной режим, обеспечивающий более высокую эффективность сэмплирования за счёт полной непрерывности целевой функции.

Полная процедура сборки модели и сэмплирования объединена с фазой предобработки в функцию `run_variant`, которая возвращает как объект трассировки MCMC, так и апостериорные вероятности положения точки разладки для каждого анализируемого сейсмического события.

4. Полный перебор по метрике LOO-ELPD

Постановка задачи выбора модели

Описанная в предыдущих разделах байесовская changepoint-модель является не единичной моделью, а целым семейством, порождаемым комбинациями нескольких факторов предобработки данных и статистических допущений. Каждая такая комбинация образует отдельную вероятностную модель, которая делает собственные предсказания о положении точки разладки τ и величине сдвига параметров. Естественно возникает вопрос: какая из этих моделей наилучшим образом описывает наблюдаемые данные? Поскольку наша цель — не просто подогнать параметры под имеющиеся наблюдения, а проверить устойчивость обнаруженных закономерностей, мы прибегаем к сравнению моделей по качеству их предсказательной способности на новых, ещё не наблюдавшихся данных.

Пространство перебора

Факторы, определяющие конкретную конфигурацию модели, можно разделить на две группы: параметры предобработки временных рядов и параметры вероятностной модели.

Параметры предобработки:

- **Ширина скользящего окна** $W \in \{2, 3, 6\}$ ч. — определяет, за какой временной интервал вычисляется доля парадоксального сна (REM%).
- **Шаг смещения окна** $S \in \{1, 2\}$ ч. — задаёт частоту, с которой вычисляются значения REM%.
- **Число временных чанков** $K \in \{8, 16\}$. — на сколько равных частей разбивается нормированный 8-дневный профиль; при $K = 8$ каждый чанк примерно соответствует суткам, при $K = 16$ — полусуткам.
- **Группировка чанков** $\in \{\text{concat}, \text{odd}, \text{even}\}$. — способ объединения чанков для вычисления описательных статистик: **concat** объединяет чётный и соседний нечётный чанк (16 чанков $\rightarrow$ 8 пар) для получения суточной метрики; **odd** использует только нечётные чанки (условно «дневные»); **even** — только чётные (условно «ночные»). Во всех случаях результатом является ряд длиной 8 значений на признак.
- **Набор статистик чанков** $\subseteq \{\text{mean}, \text{range}, \text{std}, \text{skew}, \text{kurt}\}$. — описательные статистики, вычисляемые внутри каждого чанка (или пары чанков для **concat**): среднее, размах, стандартное отклонение, смещение, эксцесс.

Параметры вероятностной модели:

- **Семейство правдоподобия** $\in \{\text{normal}, \text{student_t}, \text{lognormal}, \text{gamma}, \text{beta}\}$. — каким распределением описывается каждый признак в фоновом и аномальном режимах.

Полное декартово произведение перечисленных факторов образует конечное, но достаточно обширное пространство конфигураций. Стратегия **полного перебора** (exhaustive search) заключается в том, чтобы построить, обучить (провести МСМС-сэмплирование) и оценить качество *каждой* конфигурации из этого пространства. Такой подход, в отличие от жадных или эволюционных стратегий поиска, гарантирует, что мы не пропустим локально оптимальное решение и получим полную картину того, как различные факторы влияют на предсказательную силу модели.

Кросс-валидация временных рядов по методу LOO

Традиционная перекрёстная проверка (cross-validation) оценивает обобщающую способность модели, разбивая данные на обучающую и проверочную части, обучая модель на первой и измеряя ошибку предсказаний на второй. В случае независимых наблюдений стандартным подходом является k -кратная кросс-валидация со случайным разбиением на блоки. Однако для временных рядов такой подход неприменим: случайное перемешивание разрушает временную структуру и создаёт нереалистично оптимистичные оценки, поскольку модель получает доступ к «будущим» наблюдениям [?].

Альтернативой служит **leave-one-out кросс-валидация** (LOO-CV), адаптированная для временных рядов. В этом методе из обучающей выборки последовательно исключается ровно одно наблюдение (в нашем случае — одно сейсмическое событие), модель переобучается на оставшихся $E - 1$ событиях, после чего вычисляется логарифмическое правдоподобие исключённого события при найденных параметрах. Процедура повторяется для каждого события, давая вектор из E значений логарифмического правдоподобия.

LOO-ELPD и преимущество перед наивным LOO

Наивная LOO-оценка ожидаемой логарифмической предсказательной плотности (expected log predictive density, ELPD) определяется как сумма логарифмических правдоподобий на отложенных наблюдениях:

$$\widehat{\text{elpd}}_{\text{LOO}} = \sum_{e=1}^E \log p(\mathcal{D}_e \mid \mathcal{D}_{-e}), \quad (15)$$

где $\mathcal{D}_e$ — данные e -го сейсмического события, $\mathcal{D}_{-e}$ — все события, кроме e -го, а $p(\mathcal{D}_e \mid \mathcal{D}_{-e})$ — предсказательная плотность для e -го события, полученная путём усреднения правдоподобия по апостериорным параметрам, найденным по $\mathcal{D}_{-e}$.

Основная проблема формулы (15) в том, что она требует *полного переобучения* модели E раз, по одному разу для каждого исключаемого события. При байесовском МСМС-сэмплировании, где обучение одной модели может занимать минуты или десятки минут, такая процедура становится вычислительно непозволительной для пространства из сотен или тысяч конфигураций.

Решением служит **приближение Парето-сглаженной важности выборки** (Pareto-smoothed importance sampling, PSIS), предложенное в работе [?] и реализованное в библиотеке ArviZ [?]. Ключевая идея метода состоит в том, чтобы обучить модель *единожды* на всех E событиях, а затем оценить вклад каждого наблюдения в апостериорное распределение с помощью перевзвешивания важностных весов. Иными словами, вместо того чтобы исключать событие и переучиваться, мы корректируем вклад этого события в уже вычисленное полное апостериорное распределение.

Формально, пусть $\boldsymbol{\theta}^{(s)} \sim p(\boldsymbol{\theta} \mid \mathcal{D})$ для $s = 1, \dots, S$ — выборочные значения параметров из полного апостериорного распределения. Стабилизированные важностные веса $w_e^{(s)}$ для события e определяются через отношение правдоподобий с последующим сглаживанием хвостов распределения весов с помощью аппроксимации обобщённым распределением Парето. Тогда PSIS-оценка ELPD принимает вид:

$$\widehat{\text{elpd}}_{\text{LOO}} = \sum_{e=1}^E \log \left(\frac{\sum_{s=1}^S w_e^{(s)} p(\mathcal{D}_e \mid \boldsymbol{\theta}^{(s)})}{\sum_{s=1}^S w_e^{(s)}} \right). \quad (16)$$

Данная оценка асимптотически эквивалентна наивной LOO-CV, но требует лишь одного запуска МСМС, а не E запусков [?]. Вычислительная экономия достигает E -кратного размера, что и делает полный перебор практически осуществимым в рамках данной работы.

Особенности вычисления ELPD для многомерных событий

В стандартной постановке PSIS-LOO каждое «наблюдение» y_i представляет собой отдельное измерение — скалярную величину. Однако в нашей задаче одно наблюдение — это **целое сейсмическое событие**, описываемое многомерным временным рядом признаков парадоксального сна. Каждое событие e характеризуется набором из F активных признаков (например, среднее и размах профиля REM), каждый из которых представлен вектором из T временных чанков ($T = 8$ для всех типов группировки: `even`, `odd` и `concat`). Таким образом, полная размерность одного события составляет $M = F \times T$ скалярных измерений.

Предполагая условную независимость признаков при фиксированных параметрах модели, совместное правдоподобие события e факторизуется в произведение правдоподобий отдельных измерений:

$$p(\mathcal{D}_e \mid \boldsymbol{\theta}) = \prod_{f=1}^F \prod_{t=1}^T p(y_{e,f,t} \mid \boldsymbol{\theta}_f), \quad (17)$$

где $\boldsymbol{\theta}_f$ — параметры распределения для f -го признака. Соответственно, логарифмическое правдоподобие события есть сумма логарифмов:

$$\log p(\mathcal{D}_e \mid \boldsymbol{\theta}) = \sum_{f=1}^F \sum_{t=1}^T \log p(y_{e,f,t} \mid \boldsymbol{\theta}_f). \quad (18)$$

Из этого следует, что вклад каждого события в итоговый $\widehat{\text{elpd}}_{\text{LOO}}$ пропорционален числу активных признаков F . Модель, использующая 5 признаков, будет иметь суммарный ELPD примерно в 5 раз больший, чем модель с одним признаком, даже если дополнительные признаки не несут содержательной информации о предсейсмических изменениях. По этой причине прямое сравнение моделей с разным числом признаков по суммарному ELPD некорректно.

Для обеспечения сопоставимости моделей вводится **нормирован-**

ный показатель — ожидаемая логарифмическая предсказательная плотность в расчёте на один признак:

$$\overline{\text{elpd}}_{\text{LOO}} = \frac{\widehat{\text{elpd}}_{\text{LOO}}}{F}, \quad (19)$$

где F — число активных признаков в данной конфигурации. Именно эта метрика используется для ранжирования моделей в процедуре полного перебора.

Диагностика Парето $\hat{k}$

Качество PSIS-приближения контролируется с помощью диагностики **Парето** $\hat{k}$. Для каждого наблюдения e вычисляется оценка параметра формы обобщённого распределения Парето $\hat{k}_e$, которая характеризует толщину хвоста распределения важностных весов [? ?]:

- $\hat{k}_e < 0.5$ — приближение надёжно, наблюдение не оказывает чрезмерного влияния на апостериорное распределение;
- $0.5 \leq \hat{k}_e < 0.7$ — приближение приемлемо, но следует интерпретировать результат с осторожностью;
- $\hat{k}_e \geq 0.7$ — приближение ненадёжно; такое наблюдение является *влиятельным* (influential), и для него рекомендуется провести полноценное переобучение модели без этого наблюдения.

В контексте полного перебора наличие наблюдений с высоким $\hat{k}$ сигнализирует о том, что отдельные сейсмические события (или особи) настолько сильно отличаются от остальных, что их исключение кардинально меняет апостериорные выводы.

Процедура исключения влиятельных событий

Для получения объективной оценки предсказательной способности моделей, не зависящей от единичных выбросов, в данной работе реализо-

вана следующая процедура:

- 1) Для каждой модели в полном переборе вычисляются $\widehat{\text{elpd}}_{\text{LOO}}$ и значения $\hat{k}_e$ для всех событий $e = 1, \dots, E$.
- 2) Если хотя бы одно событие имеет $\hat{k}_e \geq 0.7$, модель признаётся содержащей влиятельные наблюдения.
- 3) Такая модель **переобучается заново** на усечённой выборке, из которой исключены все события с $\hat{k}_e \geq 0.7$. Обозначим число оставшихся событий через $E' < E$.
- 4) Для переобученной модели вычисляется новое значение $\widehat{\text{elpd}}_{\text{LOO}}$ на E' событиях.

Поскольку разные модели могут исключить разное число событий, прямое сравнение их по суммарному ELPD становится некорректным: модель, исключившая 3 события из 20, будет иметь заведомо более низкий суммарный ELPD, чем модель, не исключившая ни одного, просто за счёт меньшего числа слагаемых в сумме (16). Для устранения этого эффекта вводится **нормировка на число событий**:

$$\widetilde{\text{elpd}}_{\text{LOO}} = \frac{\widehat{\text{elpd}}_{\text{LOO}}}{E'}, \quad (20)$$

где E' — число событий, фактически использованных при обучении и оценке данной модели. Эта величина интерпретируется как средняя ожидаемая логарифмическая предсказательная плотность на одно событие.

Таким образом, итоговое ранжирование моделей после исключения влиятельных событий производится по **дважды нормированной** метрике — средней логарифмической предсказательной плотности на один признак одного события:

$$\overline{\overline{\text{elpd}}}_{\text{LOO}} = \frac{\widehat{\text{elpd}}_{\text{LOO}}}{F \times E'}. \quad (21)$$

Модели, для которых исключение влиятельных событий привело к существенному росту этой метрики, интерпретируются как устойчивые:

их высокая предсказательная способность не обусловлена подгонкой под единичные выбросы. Напротив, модели, чьё качество резко падает после исключения влиятельных событий, скорее всего, «переобучены» под индивидуальные особенности конкретных событий или особей.

Сравнение моделей по ELPD

Итогом полного перебора является таблица, в которой каждой конфигурации модели сопоставлены значения $\widehat{\text{elpd}}_{\text{LOO}}$, $\overline{\text{elpd}}_{\text{LOO}}$ (нормировка на признак) и, при наличии влиятельных событий, $\overline{\overline{\text{elpd}}}_{\text{LOO}}$ (двойная нормировка). Для каждой из этих метрик вычисляется стандартная ошибка:

$$SE_{\text{elpd}} = \sqrt{\frac{1}{E} \sum_{e=1}^E (\text{elpd}_e - \overline{\text{elpd}})^2}, \quad (22)$$

где elpd_e — вклад e -го события в общую сумму, а $\overline{\text{elpd}}$ — среднее этих вкладов.

Для пары моделей A и B разность $\Delta\widehat{\text{elpd}} = \widehat{\text{elpd}}_A - \widehat{\text{elpd}}_B$ характеризует, насколько модель A превосходит модель B в единицах логарифмической предсказательной плотности. Грубое эвристическое правило [?] гласит: если $|\Delta\widehat{\text{elpd}}| < 4$, различие между моделями статистически незначимо; при $4 \leq |\Delta\widehat{\text{elpd}}| < 8$ различие слабо выражено, и только при $|\Delta\widehat{\text{elpd}}| \geq 8$ можно уверенно говорить о превосходстве одной модели над другой. Более строгий вывод даёт построение доверительного интервала для разности с использованием парной t -статистики по E наблюдениям.

Интерпретация результатов перебора

Полный перебор по LOO-ELPD решает три взаимосвязанные задачи, соответствующие целям исследования:

- 1) **Выбор оптимальной конфигурации.** Модель с максимальным значением нормированного ELPD признаётся наилучшей с точки зрения

предсказательной способности. Её параметры (ширина окна, число чанков, группировка, набор статистик, семейство правдоподобия) интерпретируются как оптимальные для обнаружения предсейсмических аномалий парадоксального сна.

- 2) **Проверка гипотезы об аномалии.** Если даже наилучшая changepoint-модель *не* демонстрирует содержательного превосходства над нулевой моделью (моделью без точки разладки, у которой $\theta_1 = \theta_2$ для всех признаков), это свидетельствует против гипотезы о существовании устойчивого предсейсмического отклика. Напротив, значимое превосходство changepoint-модели по ELPD является свидетельством в пользу гипотезы.
- 3) **Определение оптимальной ширины аномального окна.** Анализ апостериорного распределения $p(\tau \mid \mathcal{D})$ для наилучшей конфигурации даёт прямую вероятностную оценку того, за сколько суток до (и после) сейсмического события происходит изменение динамики сна. Если апостериорная масса сконцентрирована в узком диапазоне значений τ , это указывает на специфичное временное окно предвестника; если же распределение τ близко к равномерному — либо окно слишком широко, либо эффект отсутствует.

Важно подчеркнуть, что LOO-ELPD, как и любая предсказательная метрика, оценивает не «истинность» модели в научном смысле, а её способность к обобщению. Модель, оптимальная по ELPD, может быть не единственной — несколько конфигураций с близкими значениями метрики образуют множество практически эквивалентных моделей. Анализ устойчивости выводов внутри этого множества, а также сравнение результатов до и после исключения влиятельных событий, составляют важную часть обсуждения результатов.

5. Программная реализация полного перебора

Если в предыдущем разделе рассматривалась программная реализация *одной* конфигурации байесовской changepoint-модели, то настоящий раздел посвящён надстройке, обеспечивающей автоматизированный **полный перебор** (exhaustive search) всех допустимых конфигураций, их оценивание и ранжирование по предсказательной способности.

Общая архитектура перебора

Полный перебор реализован в виде конвейера из шести последовательных этапов, каждый из которых оформлен как отдельная функция модуля `rem_profiles_export_10days_lib.py`:

- 1) **Генерация сетки конфигураций** — функция `_generate_exhaustive_configs`.
- 2) **Дедупликация** — функция `_exhaustive_model_signature` исключает вырожденные повторы.
- 3) **Цикл по конфигурациям**: для каждой конфигурации выполняются:
 - формирование матриц признаков (`build_group_data`);
 - построение вероятностного графа (`build_changepoint_model`);
 - MCMC-сэмплирование (`sample_model`).
- 4) **Оценивание и диагностика** — функция `score_changepoint_trace` вычисляет $\widehat{\text{elpr}}_{\text{LOO}}$, $\hat{R}$, ESS, BFMI и диагностику Парето $\hat{k}$.
- 5) **Исключение влиятельных событий** — для конфигураций с высоким $\hat{k}$ производится повторное сэмплирование без соответствующих событий.
- 6) **Ранжирование и экспорт** — функции `summarize_exhaustive_search`, `export_exhaustive_search_results_to_csv` и `plot_exhaustive_search_results`.

Управляющая логика сосредоточена в функции `exhaustive_model_search`, которая получает на вход словарь `proposal_options` с описанием пространства перебора, нормированную матрицу данных `data_norm` и параметры МСМС-сэмплирования (`draws`, `tune`, `chains` и др.).

Генерация конфигураций

Функция `_generate_exhaustive_configs` формирует полное декартово произведение факторов перебора, перечисленных в разделе «Полный перебор по метрике LOO-ELPD». Каждая конфигурация описывается словарём, содержащим:

- `rem_profile_params` — параметры скользящего окна (ширина, шаг);
- `n_chunks` — число временных чанков (8 или 16);
- `feature_selection` — словарь вида `{'even': ['range'], 'odd': ['range']}`, задающий, какие описательные статистики вычисляются для каждой группировки чанков;
- `parameter_selection` — словарь, сопоставляющий каждому имени признака семейство правдоподобия (`normal`, `student_t` и др.).

Ключевой этап генерации — перебор всех непустых подмножеств пар (группировка, метрика) и всех комбинаций семейств правдоподобия для активных метрик. Это гарантирует, что в пространстве перебора присутствуют как модели с единственным признаком (например, только ночной `range`), так и модели с множеством признаков в различных группировках.

Цикл перебора и кэширование

Функция `exhaustive_model_search` итерируется по списку конфигураций. Для каждой конфигурации:

- 1) Вызывается `build_group_data` — функция, которая по спецификации `feature_selection` извлекает из нормированной матрицы нужные признаки и группировки, формируя словарь `group_data` с ключами-группировками и значениями-матрицами размера $E \times (T \cdot F_{\text{group}})$, где E — число событий, T — число чанков (8 для `even/odd`, 8 пар для `concat`), F_{group} — число метрик в данной группировке.
- 2) Вызывается `build_changepoint_model`, которая по `group_data` и `parameter_selection` строит вероятностный граф РумС с маргинализированным τ (см. раздел «Маргинализация дискретного параметра τ »).
- 3) Вызывается `sample_model` с алгоритмом NUTS; поддерживаются три бэкенда: классический `rumc`, а также JAX-совместимые `numpyro` и `blackjax`.

Оценивание и диагностика

После получения трассировки MCMC для каждой конфигурации вызывается функция `score_changepoint_trace`, которая вычисляет:

- $\widehat{\text{elpd}}_{\text{LOO}}$ — PSIS-LOO оценку ожидаемой логарифмической предсказательной плотности;
- $\overline{\text{elpd}}_{\text{LOO}} = \widehat{\text{elpd}}_{\text{LOO}}/F$ — нормировку на число активных признаков F ;
- $\widetilde{\text{elpd}}_{\text{LOO}} = \widehat{\text{elpd}}_{\text{LOO}}/E'$ — нормировку на число событий E' (актуально после исключения влиятельных событий);
- диагностики сходимости MCMC: $\hat{R}_{\text{max}}$, ESS_{min} (bulk и tail), число дивергенций NUTS, BFMI;
- апостериорные характеристики τ : среднее $\mathbb{E}[\tau]$, стандартное отклонение $\text{std}(\tau)$, энтропию;

- диагностику Парето $\hat{k}_{\max}$ и число событий с $\hat{k}_e \geq 0.7$.

Вычисление $\widehat{\text{elpd}}_{\text{LOO}}$ выполняется библиотекой ArviZ (функция `az.loo`) с аргументом `scale="log"`, что даёт оценку в единицах логарифмической правдоподобия. В качестве источника логарифмических правдоподобий используется детерминированная переменная `changepoint_pointwise_log_lik`, вычисленная в модели при маргинализации τ (см. листинг 3).

Исключение влиятельных событий

После первичного оценивания для каждой конфигурации проверяется наличие событий с $\hat{k}_e \geq 0.7$. Если такие события обнаружены, конфигурация **переобучается заново** на усечённой выборке, из которой исключены все влиятельные события. Для переобученной модели заново вычисляются все перечисленные выше метрики.

Поскольку разные конфигурации могут исключить разное число событий, для итогового ранжирования используется дважды нормированная метрика:

$$\overline{\overline{\text{elpd}}}_{\text{LOO}} = \frac{\widehat{\text{elpd}}_{\text{LOO}}}{F \times E'}, \quad (23)$$

где F — число активных признаков, E' — число событий, фактически использованных после исключения влиятельных наблюдений.

Ранжирование и экспорт результатов

Функция `summarize_exhaustive_search` формирует итоговую таблицу, в которой все конфигурации ранжированы по убыванию $\overline{\overline{\text{elpd}}}_{\text{LOO}}$. Дополнительно применяются фильтры качества:

- $\hat{R}_{\max} \leq 1.05$ (сходимость цепей);
- $\text{ESS}_{\min} \geq 300$ (достаточный эффективный размер выборки);
- отсутствие дивергенций NUTS.

Конфигурации, не прошедшие фильтры, помечаются как невалидные и исключаются из итогового ранжирования.

Результаты экспортируются в два файла:

- `exhaustive_search_results.csv` — полная таблица с построчной информацией о каждой конфигурации (метрики, диагностики, сериализованная спецификация);
- `exhaustive_search_summary.json` — агрегированная сводка (число конфигураций, топ-5 моделей, распределение метрик качества).

Визуализация результатов осуществляется функцией `plot_exhaustive_search_results`, которая строит четыре диагностических графика:

- 1) $\overline{\text{elpd}}_{\text{LOO}}$ в зависимости от ранга модели (лучшие модели — справа);
- 2) $\mathbb{E}[\tau]$ с планками погрешностей $\pm 1\text{std}(\tau)$ в зависимости от нормированного ELPD;
- 3) распределение $\text{ESS}_{\min}$ по моделям;
- 4) распределение максимального Парето $\hat{k}$ по моделям с отметками пороговых значений 0.5 и 0.7.

Связь с описанной ранее реализацией одной модели

Все компоненты, задействованные в цикле перебора — `build_group_data`, `build_changepoint_model`, `sample_model` — это те же функции, которые были подробно рассмотрены в разделе «Программная реализация модели». Полный перебор не дублирует их логику, а использует как «строительные блоки», добавляя к ним автоматическую генерацию конфигураций, цикл перебора, вычисление нормированных метрик и процедуру исключения влиятельных событий.

Литература

1. Jim Albert. *Bayesian Computation with R*. Springer, New York, NY, 2 edition, 2009.
2. Cameron Davidson-Pilon. *Bayesian Methods for Hackers: Probabilistic Programming and Bayesian Inference*. Addison-Wesley, 2015. URL <https://github.com/CamDavidsonPilon/Probabilistic-Programming-and-Bayesian-Methods-for-Hackers>. Includes the text-message change-point example.
3. Alain Durmus, Samuel Gruffaz, Miika Kailas, Eero Saksman, and Matti Vihola. On the convergence of dynamic implementations of Hamiltonian Monte Carlo and No U-turn samplers, 2023. URL <https://arxiv.org/abs/2307.03460>.
4. Guangzhan Fang, Yiwen Xia, Chunguang Zhang, Tiejun Liu, and Dezhong Yao. Optimized single electroencephalogram channel sleep staging in rats. *Laboratory Animals*, 44:312–322, 2010. doi: 10.1258/la.2010.009081.
5. Matthew D. Hoffman and Andrew Gelman. The no-U-turn sampler: Adaptively setting path lengths in Hamiltonian Monte Carlo. *Journal of Machine Learning Research*, 15:1593–1623, 2014. URL <https://www.jmlr.org/papers/v15/hoffman14a.html>.
6. Jinlin Lai, Javier Burroni, Hui Guan, and Daniel Sheldon. Automatically marginalized MCMC in probabilistic programming, 2023. URL <https://arxiv.org/abs/2302.00564>.
7. Anton Saevskiy, Natalia Suntsova, Peter Kosenko, Md Noor Alam, and Andrey Kostin. Open-source algorithm for automated vigilance state classification using single-channel electroencephalogram in rodents. *Sensors*, 25(3):921, 2025. doi: 10.3390/s25030921.
8. Vladyslav V. Vyazovskiy and Irene Tobler. Theta activity in the waking EEG is a marker of sleep propensity in the rat. *Brain Research*, 1050(1–2): 64–71, 2005. doi: 10.1016/j.brainres.2005.05.022.

Приложение

Ниже приведены расширенные листинги функций модуля `rem_profiles_export_10days_lib.py`, дополняющие краткие фрагменты в подразделе «Байесовский метод».

Листинг 4. Полная реализация `_build_prior`

```
def _build_prior(var_name: str, spec: dict, *, positive_only:

    positive_dists = {"halfnormal", "halfstudentt", "exponential",
                      "lognormal", "exponential_plus"}
    if dist == "normal":
        return pm.Normal(var_name, mu=float(spec.get("mu", 0.0)),
                          sigma=float(spec.get("sigma", 1.0)))
    if dist == "halfnormal":
        return pm.HalfNormal(var_name,
                              sigma=float(spec.get("sigma", 1.0)))
    if dist == "halfstudentt":
        return pm.HalfStudentT(
            var_name,
            nu=float(spec.get("nu", 4.0)),
            sigma=float(spec.get("sigma", 1.0)),
        )
    if dist == "exponential":
        return pm.Exponential(var_name,
                               lam=float(spec.get("lam", 1.0)))
    if dist == "lognormal":
        return pm.LogNormal(
            var_name,
            mu=float(spec.get("mu", 0.0)),
            sigma=float(spec.get("sigma", 1.0)),
        )
    if dist == "exponential_plus":
        lam = float(spec.get("lam", 0.05))
        offset = float(spec.get("offset", 2.0))
        raw = pm.Exponential(f"{var_name}_raw", lam=lam)
        return pm.Deterministic(var_name, raw + offset)
```

Листинг 5. Каркас `build_changepoint_model`: режимы τ и маргинализация (прочие ветви правдоподобия опущены)

```
def build_changepoint_model(
```

```

group_data: dict,
tau_lower: int = 2,
tau_upper: int | None = None,
parameter_selection: dict | None = None,
tau_mode: str = "discrete",
):
    first_group = next(iter(group_data.values()))
    first_feat = next(iter(first_group.values()))
    n_group_chunks = first_feat.shape[1]

    if tau_upper is None:
        tau_upper = n_group_chunks
    active_features = {feat for features in group_data.values()
                        for feat in features.keys()}
    parameter_cfg = _parse_parameter_selection(
        parameter_selection, active_features)

    with pm.Model() as model:
        idx = np.arange(n_group_chunks)
        tau_values = np.arange(tau_lower, tau_upper + 1,
                               dtype=np.int64)
        n_tau = tau_values.size

        if tau_mode == "discrete":
            tau = pm.DiscreteUniform("tau", lower=tau_lower,
                                     upper=tau_upper)

            loglik_by_tau = None
            mask_before = None
        else:
            mask_before = (
                idx[None, :] < (tau_values[:, None] - 1)
            ).astype(float)
            loglik_by_tau = np.zeros(n_tau, dtype=float)

        for group_name, features in group_data.items():
            for feat_name, observed_df in features.items():
                observed = observed_df.to_numpy()
                spec = parameter_cfg[feat_name]
                likelihood = str(spec.get("likelihood",
                                           "normal")).strip().lower()
                _ = (observed, spec, likelihood)
# ... ветвление по likelihood; накопление loglik_by_tau

        if tau_mode == "marginalized":
            log_w = loglik_by_tau - np.log(float(n_tau))

```



```

pm.Potential("tau_marginalized_logp",
             pm.math.logsumexp(log_w))
tau_probs = pm.Deterministic("tau_probs",
                             pm.math.softmax(log_w))
tau_support = pm.Deterministic(
    "tau_support",
    pt.as_tensor_variable(
        tau_values.astype(np.float64)
    ),
)
pm.Deterministic(
    "tau_mean",
    pm.math.sum(tau_probs * tau_support),
)

return model

```